

附录 | 阅读清单

阅读清单

这份清单不是“多读点资料就会更强”的泛读库，而是按当前课程主线整理出来的补充阅读入口。优先级很明确：先读能直接帮助你完成当前周交付的，再读扩展材料。

基础主线

主题	推荐材料	为什么值得读
系统边界与工程判断	Designing Data-Intensive Applications	对“状态、日志、复制、批处理、流处理”建立长期判断框架。
数据工程基本盘	Fundamentals of Data Engineering	对 pipeline、ownership、orchestration、lakehouse 有系统化认识。
数据仓库分层	The Data Warehouse Toolkit	帮你理解为什么 Bronze / Silver / Gold 不是随意命名。

Week02 | 输入准入、契约、Metadata

主题	推荐材料	为什么值得读
Data Contract	Data Contract 相关文章与工程实践总结	帮你把“字段清单”升级成“系统准入边界”。
Metadata / Lineage / Provenance	数据治理、血缘与审计相关资料	帮你理解 metadata 为什么先于 chunking 和 serving。
PII / 数据合规	隐私字段分级与数据最小化资料	帮你把 PII 从布尔判断升级成动作矩阵。

Week03 | Ingest、状态、恢复

主题	推荐材料	为什么值得读
Batch / Incremental / CDC	批流一体、CDC、exactly-once 限制相关资料	帮你建立 cursor、checkpoint、replay、backfill 的边界判断。
Idempotency / Dedupe	幂等写入与重复保护实践	帮你区分 dedupe key 和 idempotency key。
Runbook / Incident Response	运行手册与故障恢复案例	帮你理解为什么 recovery thinking 需要提前进入设计。

Week04 | Lakehouse 底座——Iceberg 快照/演进/性能基线

主题	推荐材料	为什么值得读
Iceberg 表状态与可靠性	Apache Iceberg Reliability	用官方定义理解 snapshot、history、rollback 和 time travel 为什么是“表状态能力”，不是查询小技巧。
Schema / Partition Evolution	Apache Iceberg Evolution 与 Partitioning	帮你把 schema evolution、hidden partitioning 和兼容性判断拆开。
Metadata 与性能维护	Apache Iceberg Maintenance 与 Performance	帮你理解 file count、metadata、compaction 和 scan planning 为什么会进入 Week04 baseline。
Pylceberg 本地运行	Pylceberg Configuration 与 Pylceberg API	对齐课程里的 devbox CLI、SQL catalog、table load 和 metadata inspection。
OmniSupport Copilot Week04 Runbook	runbooks/week04/README.md	这是学生执行 Week04 实验时最应该对齐的真实项目入口。
Course Site Sync Packet	docs/blueprints/week04/course_site_sync_packet_v1.md	用来确认讲义中的路径和命令是否已经在 <code>omnisupport-copilot</code> 仓库真实存在。

Week05 | Transform 与语义层——把口径写进工程 (给 BI 也给 Agent 用)

主题	推荐材料	为什么值得读
dbt Core / Modeling	dbt Docs: Models 与 Project structure	Week05 的 sources、staging、intermediate、marts 都从这里建立分层判断。
dbt Sources	dbt Docs: Sources	帮你理解为什么真实上游必须先被声明，而不是让下游模型猜表。
dbt Data Tests	dbt Docs: Data tests	帮你把“SQL 能跑”升级成“关键口径假设被自动检查”。
dbt Unit Tests	dbt Docs: Unit tests	帮你处理 reopen、escalation、first response 这类复杂 SQL 边界逻辑。
dbt Documentation	dbt Docs: Documentation 与 docs generate	帮你理解 docs、catalog 和 lineage 为什么是交付证据。
dbt Artifacts	dbt Docs: Artifacts 、 manifest.json 、 run_results.json	帮你理解 <code>manifest.json</code> 、 <code>catalog.json</code> 、 <code>run_results.json</code> 在 evidence 中的作用。

主题	推荐材料	为什么值得读
dbt Semantic Layer	dbt Docs: Semantic Layer	帮你理解本地 registry 未来可以迁移到什么平台能力，但本周不把平台作为硬依赖。
Semantic Models / Metrics	Semantic models 与 Metrics	帮你区分 entity、dimension、measure、metric。
MetricFlow	dbt Docs: MetricFlow commands	作为语义查询的扩展理解，不作为 Week05 Student Core 必跑项。
OpenAI Function Calling	OpenAI Docs: Function Calling	帮你理解 Agent 为什么应该通过工具契约调用指标。
OpenAI Structured Outputs	OpenAI Docs: Structured Outputs	帮你理解严格结构化输出和工具审计的关系。
JSON Schema	Understanding JSON Schema	帮你理解 required、enum、additionalProperties 等 schema 约束。
Quarto 写作	Callouts 、 Mermaid 、 HTML code blocks	作为课程站点实现参考，保持代码块、图示和 callout 与整站一致。

Week06 | 资产化数据工厂——编排、回填与可追溯

主题	推荐材料	为什么值得读
Dagster Assets	Dagster Docs: Assets	帮你理解 Week06 为什么以 asset graph 表达数据产品，而不是普通任务流。
Dagster Materialization Metadata	Dagster Docs: Asset materializations and metadata	帮你判断哪些信息适合放到 Dagster metadata，哪些应该落到 report / evidence。
Dagster Asset Observations	Dagster Docs: Asset observations	帮你处理 Week04 / Week05 optional dependency：观察它们，但不 fake passed。
Dagster Asset Checks	Dagster API: Asset checks	帮你区分 pytest、asset check 和 run evidence 的职责。
Dagster Partitions and Backfills	Dagster Docs: Partitions and backfills	帮你把 Week03 的 recovery 思维升级到明确分区上的受控恢复动作。
Dagster Backfilling Data	Dagster Docs: Backfilling data	帮你理解 backfill 为什么需要选择范围、观察影响面，而不是一失败就全量重跑。

主题	推荐材料	为什么值得读
OpenLineage About	OpenLineage Docs	作为 Week14 方向的铺垫，理解为什么运行证据和血缘最终要跨系统表达。
OpenLineage Object Model	OpenLineage Object Model	帮你理解 run、job、dataset 这些对象如何成为可审计证据。
OpenLineage Facets	OpenLineage Facets	帮你理解为什么 metadata / evidence 需要结构化，而不是只写日志。
Quarto 写作	Callouts 、 Mermaid 、 Website navigation	作为课程站点实现参考，保证 Week06 图示、callout 和导航不破坏整站风格。
OmniSupport Copilot Week06 Runbook	runbooks/week06-data-factory.md	学生执行 Week06 实验和作业时最应该对齐的真实项目入口。
Course Site Sync Notes	reports/week06/course_site_sync_notes.md	用来确认课程讲义中的 Week06 路径、命令和项目实现保持一致。

Week 7: 非结构化数据工程

主题	推荐材料	为什么值得读
Docling 总览	Docling docs	帮你理解为什么 Week7 选择 Docling-first，而不是只做 PDF to text。
DoclingDocument	DoclingDocument concept	理解 parsed document 如何表达 text、table、picture、page、bbox 和 provenance。
Docling Chunking	Docling chunking	对照 section_aware_v1 ，理解结构感知 chunking 的价值。
Unstructured Elements	Unstructured document elements	帮你把 fallback route 当作对象模型对照，而不是替代 Week7 主线。
Unstructured Metadata	Unstructured metadata	对照 source、page、coordinates 等字段，理解 evidence anchor 需要哪些事实。
Azure Layout	Azure Document Intelligence Layout	作为 Instructor Scale 参考，理解 page / bbox / table extraction 的上限能力。
LangChain Splitters	Recursive text splitter	理解固定长度和递归切分的边界，不把它当作唯一方案。

主题	推荐材料	为什么值得读
LlamaIndex Node Parsers	Node parser guide	扩展理解 node / chunk / meta-data 的关系。
JSON Schema	Understanding JSON Schema	Week7 的 section、chunk、anchor 和 gate 都要先有可测试 schema。
Quarto 写作	Callouts 、 Mermaid	保持 Week7 页面和整站一致, 不引入新视觉系统。

Week 8 | 检索 × 生成的一体化工程闭环

主题	推荐材料	为什么值得读
pgvector	pgvector README	帮你理解 PostgreSQL 内的向量列、距离函数和索引能力。
PostgreSQL Full Text Search	PostgreSQL Text Search	Week8 的 FTS 路线来自 PostgreSQL 原生能力, 不需要额外搜索引擎作为 Student Core。
Hybrid Search / RRF	Reciprocal Rank Fusion 相关资料	帮你理解为什么 vector 和 FTS 不应该直接相加分数。
Sentence Transformers Cross-Encoder	Cross Encoder Usage	理解 rerank 为什么只处理 Top-N candidates, 并且应该支持不可用 fallback。
OpenAI Structured Outputs	Structured Outputs	作为结构化 RAG response 的实现参考; 即使不用 OpenAI, 也要先过本地 schema validation。
JSON Schema	Understanding JSON Schema	帮你把 RAG request、response、citation 和 index manifest 写成可测试契约。
Prompt as Code	Prompt 版本化和发布管理实践	帮你理解为什么 <code>prompt_release_id</code> 应该进入 response 和 audit。
RAG Evaluation	RAG smoke / regression evaluation 资料	Week8 只做 smoke eval, Week11 才做完整评测体系。

Week 9 | Agent Skills 开放标准与可移植 workflow

主题	推荐材料	为什么值得读
Agent Skills 设计	Codex / Claude Code 等 Agent skills 机制相关文档	帮你理解 skill 不是 prompt, 而是可发现、可执行、可验证的工作流资产。

主题	推荐材料	为什么值得读
Progressive Disclosure	大型上下文分层加载实践	帮你判断哪些内容应该进入 SKILL.md ，哪些应该放进 references/ 按需加载。
Repository-scoped Automation	仓库内工具、脚本、模板和验证清单实践	帮你把个人经验封装成团队可复现的 skill pack，而不是本机配置。
JSON Schema / YAML Manifest	Understanding JSON Schema	Week09 的 manifest、validation report 和 release check 都需要机器可读边界。
Runbook 工程化	Incident runbook 与 release checklist 实践	帮你把 Week03–Week08 的恢复、契约、RAG 和发布动作封装成安全 skill。

RAG / Agent 扩展阅读

主题	推荐材料	为什么值得读
RAG 证据链与引用	检索、引用、evidence serving 实践	帮你理解为什么 Week03 / Week04 的状态层会直接影响 Week08。
Agent 工具调用与执行边界	Tool use、sandbox、审计、权限边界材料	帮你把 Agent 从“能调工具”升级成“受控的工程系统”。

阅读顺序建议

1. 如果你正在补 Week02，优先读契约、metadata、PII。
2. 如果你正在补 Week03，优先读 ingest、checkpoint、runbook。
3. 如果你正在补 Week04，优先读 Iceberg 官方文档和 Lakehouse 架构材料。
4. 如果你正在补 Week05，优先读 dbt Core 的 models / tests / docs，再读语义层材料。
5. 如果你正在补 Week06，优先读 Dagster assets、partitions/backfills、asset checks 和 observations。
6. 如果你正在补 Week7，优先读 DoclingDocument、Docling chunking、Unstructured elements 和 citation/evidence 材料。
7. 如果你正在补 Week8，优先读 pgvector、PostgreSQL FTS、JSON Schema 和 Structured Outputs，再读 rerank / eval 扩展材料。
8. 如果你正在补 Week9，优先读 Agent Skills、progressive disclosure、manifest/schema 和 runbook 工程化材料。
9. 不要一开始就横向读太多。当前周交付要解决什么，就先补那一类阅读。