

Week 7 | 课时 4 | Evidence Anchor: 让每个 chunk 可以回指原文位置

本课导航

Citation 的事实来源必须在数据阶段生成	1
这节课解决什么问题	1
先用大白话讲	1
术语拆清楚	2
参考学习时间	2
学完这一讲，你应该能做到什么	2
本课产出	2
evidence anchor 映射图	2
1. Anchor 不是装饰字段	2
2. 为什么 anchor 要在数据阶段生成	3
3. Anchor contract 最小字段	3
4. 稳定 anchor ID	4
5. page / bbox 缺失怎么处理	4
6. PDF / HTML / Markdown / DOCX 的 anchor 差异	4
7. OmniSupport 下游会怎么消费 anchor	5
8. 生产事故：看起来有来源，但回不到原文	5
本课最重要判断	5
自检清单	5
最小行动命令	5
延伸阅读	6
Footnotes	6

Citation 的事实来源必须在数据阶段生成

这一讲把 Week7 的证据链收紧：

每个 chunk 至少要有个 evidence anchor，告诉 Week8 它来自哪个文件、哪个版本、哪一页、哪个 section、哪个 bbox。

这节课解决什么问题

很多系统把 citation 放到生成阶段，让 LLM 根据上下文“拼一个来源”。这会留下两个根本问题：

- 引用可能不是检索结果真实来源
- 出问题时无法回到原始文档定位

Week7 的做法是：

citation 只能消费 evidence anchor；LLM 不允许发明证据。

先用大白话讲

如果 chunk 是一张证据卡，那么 evidence anchor 就是卡片背面的“出处”：哪份文件、哪一版、哪一页、哪个章节、哪个坐标。如果背面没有出处，卡片上的话再像证据，也不能拿去回答用户。

OmniSupport 的目标不是“回答像不像”，而是当用户问“这句话从哪来”时，系统能把引用拉回真实文档。

术语拆清楚

对象	小白解释	工程职责
Section	文档里的章节或结构单元	保存标题层级、页码、bbox、content type
Chunk	准备进入 Week8 索引的证据片段	继承 section/source meta-data，控制长度和质量
Evidence Anchor	chunk 回源的稳定锚点	生成 citation、支持复盘和质量复核
Citation	面向用户展示的引用	只能由 evidence anchor 投影出来，不能由 LLM 编造

参考学习时间

按课程统一节奏完成即可。


学完这一讲，你应该能做什么

- 1. 区分 chunk、section 和 evidence anchor。
- 2. 设计 evidence anchor 的最小字段。
- 3. 解释为什么 anchor 需要 `source_fingerprint` 和 `doc_version`。
- 4. 判断 page/bbox 缺失时应该 fail、warn 还是 not applicable。

本课产出

- docs/blueprints/week07/evidence-anchor-contract.md
- contracts/data/evidence_anchor.schema.json

evidence anchor 映射图



1. Anchor 不是装饰字段

Evidence anchor 至少要支撑四类动作：

动作	Anchor 提供什么
citation	文件、页码、section、bbox
bad case replay	原始对象、版本、指纹、策略版本
quality review	bbox 缺失原因、质量 flags
policy filter	license、visibility、PII 状态

没有 anchor, Week8 检索出来的 chunk 就只是“像证据的文本”。

2. 为什么 anchor 要在数据阶段生成

如果放到生成阶段	会发生什么	数据阶段生成的好处
LLM 根据上下文猜 source	引用可能不是检索结果真实来源	citation 只来自已有 anchor
生成时临时拼 page / section	文档更新后难以复盘	anchor 绑定 fingerprint / version
只在 UI 展示 URL	审计和评测无法消费	anchor 可被 Week8 / Week11 / Week12 复用
缺失 bbox 时静默跳过	团队误以为可精确定位	<code>bbox_missing_reason</code> 明确记录能力边界

3. Anchor contract 最小字段

```
{
  "anchor_id": "stable_sha256_prefix",
  "source_id": "doc:workspace:helpcenter:v1",
  "chunk_id": "document_chunk_id",
  "section_id": "knowledge_section_id",
  "doc_id": "workspace_help_center_v1",
  "source_fingerprint": "sha256...",
  "doc_version": "v1",
  "page_no": 4,
  "bbox": {"x0": 0.13, "y0": 0.22, "x1": 0.84, "y1": 0.31},
  "bbox_missing_reason": null,
  "section_path": ["Setup", "SS0"],
  "source_url": "s3://omni-raw-documents/workspace-help/source.pdf",
  "content_type": "pdf",
  "license_tag": "internal_training"
}
```

最小字段清单:

字段	为什么必须有
<code>anchor_id</code>	citation 的稳定证据 ID
<code>source_id</code> / <code>doc_id</code>	绑定来源和文档
<code>section_id</code> / <code>chunk_id</code>	绑定结构单元和索引候选单元
<code>source_fingerprint</code> / <code>doc_version</code>	支撑版本回放

字段	为什么必须有
page_no / bbox / bbox_missing_reason	支撑 PDF 回指和缺失解释
section_path / source_url	支撑非分页文档定位
content_type / license_tag	支撑过滤、权限和治理

4. 稳定 anchor ID

推荐公式：

```
anchor_id = sha256(
    chunk_id
    + anchor_type
    + source_fingerprint
    + doc_version
    + page_no
    + bbox
    + section_path
)[:32]
```

这样能保证：

- 同一 chunk 重跑后 `anchor_id` 不漂移
- bbox 或 section_path 变化时，anchor ID 能反映事实变化
- Week8 citation 可以稳定引用同一证据对象

5. page / bbox 缺失怎么处理

文档类型	page_no	bbox	Week7 gate
PDF	必须有	缺失 warning, 并要求 <code>bbox_missing_reason</code>	page 缺失 hard fail
HTML / Markdown	可为空	可为空	需要 section_path 和 source_uri
DOCX	视 parser capability	视 parser capability	hierarchy 优先, bbox 作为 warning
scanned PDF	取决于 OCR	取决于 OCR	Student Core 不强制 OCR, 报告中标明限制

6. PDF / HTML / Markdown / DOCX 的 anchor 差异

类型	Anchor 重点	常见缺口
PDF	page_no、 bbox、source_fingerprint	bbox 缺失但没有 reason
HTML	source_url、section_path、DOM 语义	没有稳定 section path
Markdown	heading path、source repo path、commit/version	heading 被当成普通段落

类型	Anchor 重点	常见缺口
DOCX	paragraph hierarchy、page capability、doc_version	parser 不输出页码却没有 capability warning

7. OmniSupport 下游会怎么消费 anchor

下游	需要 anchor 做什么
Week8 retrieval / RAG	把 evidence_id、page、section、source 投影为 citation
Week11 eval	检查答案是否覆盖了正确证据
Week12 tracing	回放一次坏答案时定位检索输入和引用来源
Week14 governance	对 release、source、license、PII 和 audit 做追责

8. 生产事故：看起来有来源，但回不到原文

最危险的 citation 不是完全没有来源，而是看起来像有来源：

Source: Workspace Help Center

Quote: Reset your device and retry provisioning.

这段引用缺少 `source_fingerprint`、`doc_version`、`page_no`、`section_path` 和 `anchor_id`。当文档更新或答案被质疑时，团队只能人工全文搜索，无法证明模型引用的是哪一份事实。

本课最重要判断

Evidence anchor 是 Week8 citation、Week11 eval、Week12 tracing 和 Week14 governance 的根。它必须在数据阶段生成。

自检清单

- 我能说明 citation 为什么不能由 LLM 临时发明。
- 我知道 evidence anchor 最少要保留哪些字段。
- 我知道 PDF、HTML、DOCX 的 page/bbox gate 不一样。
- 我能解释 `source_fingerprint` 对 bad case replay 的作用。

最小行动命令

可执行：已与主项目 Week7 runbook 对齐

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  python -m pipelines.parse_normalize.run_parse \
  --manifest-path data/seed_manifests/manifest_workspace_helpcenter_v1.json \
  --parser auto \
  --chunk-strategy section_aware_v1 \
  --data-release-id week07-lesson04-anchor \
  --dry-run \
  --artifacts-dir artifacts/week07 \
  --report-json reports/week07/parse_run_report.json \
  --quality-report-md reports/week07/chunk_quality_report.md
```

延伸阅读

- DoclingDocument provenance: https://docling-project.github.io/docling/concepts/docling_document/。重点看元素如何保留 page、bbox 和 provenance。
- Unstructured metadata: <https://docs.unstructured.io/open-source/concepts/metadata>。作为 fallback 对照, 理解 source、page、coordinates 等 metadata。
- JSON Schema: <https://json-schema.org/understanding-json-schema/>。用于把 anchor contract 写成可测试边界。
- OpenAI Structured Outputs: <https://platform.openai.com/docs/guides/structured-outputs>。作为 Week8 预习, 理解为什么 citation 也要结构化输出, 但 citation 事实不能由模型生成。

Footnotes

1. Anchor 是数据资产, 不是 UI 字段。UI citation 只是 anchor 的一种展示方式。
2. PDF page_no 缺失通常应 hard fail; bbox 缺失是否 hard fail 要结合文档类型和 `bbox_missing_reason`。
3. `source_url` 不能替代 `source_fingerprint`。URL 可以指向新内容, fingerprint 才能锁定原始字节。
4. Week7 只生产 anchor, 不生产 embedding, 也不验证检索效果。