

Week 7 | 课时 5 | 解析质量与切片质检：把 Week8 索引准入做成工程门禁

本课导航

Week8 不能消费“看起来差不多”的 chunks	1
这节课解决什么问题	1
先用大白话讲	2
技术原理：质量门禁分三层	2
参考学习时间	2
学完这一讲，你应该能做到什么	2
本课产出	2
Quality Gate 仪表盘	2
质量门禁表	3
1. content-type aware gate	3
2. 样本不足也要报告	4
3. Week8 ready gate 最小输出	4
4. hard gate / warning / not applicable	5
5. PII leakage risk 只是 heuristic	5
6. Week8 消费规则	5
7. 生产反模式	5
课堂练习	5
本课最重要判断	6
自检清单	6
最小行动命令	6
延伸阅读	6
Footnotes	6

Week8 不能消费“看起来差不多”的 chunks

这一讲收口 Week7：

解析质量、chunk 质量和 evidence coverage 必须变成门禁，而不是靠人工感觉放行。

这节课解决什么问题

Week7 产出 chunks 之后，不能直接进入 Week8 索引。

必须先回答：

- metadata 是否完整
- 每个 chunk 是否有 anchor
- page_no / bbox 覆盖率是否符合文档类型
- 空 chunk、孤儿 chunk、重复 overlap 是否过高
- 是否有明显 PII leakage risk
- 样本数不足时如何说明

先用大白话讲

Week8 就像要开一个搜索引擎。如果 Week7 把坏 chunk、空 chunk、无来源 chunk 都放进去，搜索引擎只会更快地找到坏证据。

质量门禁的作用不是追求“全部绿色”，而是诚实区分：哪些可以索引，哪些需要隔离，哪些只是样本不足或 bbox 不适用。

技术原理：质量门禁分三层

层次	检查什么	失败影响
Contract gate	required fields、schema、enum、strategy version	对象边界不成立，不能交给下游
Evidence gate	anchor coverage、page reference、bbox / missing reason	citation 断链，不能支撑答案回源
Consumption gate	PII risk、license、quarantine、allowed_for_indexing	Week8 可能越权或消费低质量证据

参考学习时间

按课程统一节奏完成即可。

学完这一讲，你应该能做到什么

1. 设计 `chunk_quality_report.md` 的核心指标。
2. 区分 hard gate、warning、not applicable。
3. 按 content type 判断 page/bbox coverage。
4. 写出 `week8_ready_gate.json` 的准入结论。

本课产出

- `docs/blueprints/week07/quality-gate-spec.md`
- `reports/week07/chunk_quality_report.md`
- `reports/week07/week8_ready_gate.json`

Quality Gate 仪表板

指标	计算方式	Student Core 阈值	Gate
metadata completeness	必需字段完整 chunk 占比	100%	hard
anchor coverage	有 evidence anchor 的 chunk 占比	100%	hard
PDF page reference rate	PDF chunk 有 page_no 的占比	100%	hard
PDF bbox coverage	PDF chunk 有 bbox 或 missing reason 的占比	100%	warn / hard
empty chunk rate	空内容 chunk 占比	0%	hard

指标	计算方式	Student Core 阈值	Gate
orphan chunk rate	无 section / doc 关联 chunk 占比	0%	hard
overlap duplicate rate	overlap 重复噪声比例	需说明	warn
PII leakage risk	heuristic 命中比例	需复核	warn / quarantine

质量门禁表

指标	PDF	HTML/MD	阈值	状态	下游动作
metadata completeness	必需字段完整	必需字段完整	100%	hard	缺字段不索引
anchor coverage	每个 chunk 至少一个 anchor	每个 chunk 至少一个 anchor	100%	hard	缺 anchor 不索引
page reference coverage	page_no 必须有	not applicable	100% for PDF	hard / N/A	PDF 缺页码 fail
bbox coverage	有 bbox 或 missing reason	not applicable	100% explained	ex- warn / hard	缺解释 quarantine
empty chunk rate	0%	0%	0%	hard	空 chunk 删除并报告
orphan chunk rate	0%	0%	0%	hard	无 section/doc 不索引
overlap duplicate rate	限制在同 section	限制在同 section	必须解释	warn	进入 bad case review
PII leakage heuristic	抽样复核	抽样复核	命中需说明	warn / quarantine	可疑 chunk 隔离

1. content-type aware gate

不能用同一条 bbox 规则压所有文档。

content type	page_no	bbox	gate 解释
PDF	必须有	缺失要写原因	citation 基本条件
HTML	可为空	可为空	需要 URL / section_path
Markdown	可为空	可为空	需要 source_uri / heading path
DOCX	视 parser capability	视 parser capability	hierarchy 优先

报告必须区分：

- `overall_bbox_coverage`

- pdf_bbox_coverage
- non_paged_bbox_not_applicable_count

否则会把 HTML / Markdown 误判成解析失败。

2. 样本不足也要报告

作业要求至少 50 份文档的抽样质检流程。如果本地样本不足，不是直接跳过，而是写清：

- 当前样本数
- 缺口数量
- 抽样规则是否已实现
- 扩展到 50+ 文档时要怎么跑

这对应 sample_shortfall。

3. Week8 ready gate 最小输出

```
{
  "status": "warn",
  "allowed_for_indexing": true,
  "blocked_reason": null,
  "parse_strategy_version": "docling_v1_no_ocr",
  "chunk_strategy_version": "section_aware_v1",
  "total_chunks": 128,
  "ready_chunks": 124,
  "blocked_chunks": 4,
  "hard_failures": [],
  "warnings": ["sample_shortfall", "pdf_bbox_coverage_below_target"],
  "week8_consumption_rule": "consume pass/warn chunks with evidence_anchor only"
}
```

chunk_quality_report.md 建议至少包含这些段落：

段落	要回答
Input summary	本次处理了哪些文档、哪些 source、哪个 data release
Contract status	section / chunk / anchor schema 是否通过
Coverage metrics	metadata、anchor、page、bbox、empty、orphan、duplicate 的指标
Bad cases	至少列一个 warning / fail 样本和根因
Week8 decision	哪些 chunks 可消费，哪些 blocked / quarantined / manual review
Limitations	sample_shortfall、OCR disabled、fallback parser、非分页文档 bbox N/A

4. hard gate / warning / not applicable

类型	例子	处理
hard gate	PDF chunk 没有 <code>page_no</code> ; chunk 没有 anchor	fail / blocked
warning	bbox 缺失 但有 <code>bbox_missing_reason</code> ; 样本不足	warn, 但进入 review
not applicable	HTML / Markdown 没有 bbox	不扣分, 但必须写清 content type
quarantine	PII heuristic 命中或来源不可信	不进入 Week8 index

5. PII leakage risk 只是 heuristic

Week7 可以做明显模式检查:

- email
- phone
- token-like string
- secret-like key

但不能宣称已经完成完整合规扫描。Week12 / Week14 才会进入更完整 tracing 和 governance。

6. Week8 消费规则

Week8 只能索引满足以下条件的 chunks:

- `allowed_for_indexing=true`
- 有 `evidence_anchor`
- 不在 quarantine 列表中
- `source_fingerprint`、`doc_version`、`parse_strategy_version`、`chunk_strategy_version` 存在
- 若为 PDF, 至少有 `page_no`, bbox 缺失必须有明确 reason

7. 生产反模式

反模式	为什么危险	正确做法
报告只写“通过”	下游看不到样本数、warning 和限制	写出 metrics、warnings、blocked_reason
bbox 对所有文档一刀切	HTML / Markdown 被误判失败	content-type aware gate
样本不足直接忽略	作业看似完成, 真实覆盖不够	写 <code>sample_shortfall</code> 和扩展计划
PII heuristic 当合规扫描	误导治理判断	明确只是 heuristic, 疑似 chunk quarantine
warning 也全部索引	质量缺口进入 Week8	只有满足消费规则的 chunk 才索引

课堂练习

给你一份 `week8_ready_gate.json`:

```
{
  "status": "warn",
  "ready_chunks": 120,
  "blocked_chunks": 8,
  "warnings": ["sample_shortfall", "pdf_bbox_coverage_below_target"]
}
```

请写出 Week8 应该怎么消费：哪些 chunks 可以进入索引，哪些要 blocked，哪些需要 bad case review，报告里还缺哪些字段。

本课最重要判断

质量报告不是附录，而是 Week8 的准入门禁。没有 quality gate，就不应该建索引。

自检清单

- 我能设计 content-type aware page/bbox gate。
- 我能解释 sample_shortfall 不是失败，而是可交接限制。
- 我知道 PII risk 在 Week7 只是 heuristic。
- 我能写出 Week8 ready gate 的消费规则。

最小行动命令

```
# 可执行：已与主项目 Week7 runbook 对齐
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python -m pipelines.parse_normalize.run_parse \
    --manifest-path data/seed_manifests/manifest_workspace_helpcenter_v1.json \
    --parser auto \
    --chunk-strategy section_aware_v1 \
    --data-release-id week07-lesson05-gate \
    --dry-run \
    --artifacts-dir artifacts/week07 \
    --report-json reports/week07/parse_run_report.json \
    --quality-report-md reports/week07/chunk_quality_report.md \
    --week8-gate-json reports/week07/week8_ready_gate.json
```

延伸阅读

- JSON Schema: <https://json-schema.org/understanding-json-schema/>。用于把 quality gate 输入输出变成可测试对象。
- Great Expectations 核心概念: <https://docs.greatexpectations.io/docs/core/introduction/>。作为数据质量门禁的扩展参考，不作为本周硬依赖。
- OpenLineage object model: <https://openlineage.io/docs/spec/object-model/>。作为 Week14 预习，理解为什么运行和数据证据需要结构化。
- Quarto callouts: <https://quarto.org/docs/authoring/callouts.html>。用于写清 pass/warn/fail 结论，不引入额外前端体系。

Footnotes

1. warn 不等于失败，但必须写清下游消费规则和人工复核动作。

2. `not applicable` 只适用于文档类型确实不支持某类定位信息，例如 HTML 无 `bbox`；不能用它掩盖 parser 丢失 PDF page。
3. `sample_shortfall` 是一种诚实限制，不应被隐藏。
4. Week7 的 PII 检查只是 heuristic；完整治理和审计会在后续周次展开。