

Week 8 | 课时 5 | RAG API 契约化：结构化输出、引用证据、Prompt as Code、审计日志

本课导航

最终交付的不是一个聊天接口，而是一条可审计的 RAG 服务契约	1
这节课解决什么问题	1
参考学习时间	1
先看一张总图	1
1. RAG Request 最小字段	1
2. Prompt as Code	2
3. Audit log 记录什么	2
4. Smoke eval 不等于 full eval	2
5. 最终 API 调用	3
本课最重要判断	3
自检清单	3

最终交付的不是一个聊天接口，而是一条可审计的 RAG 服务契约

这一讲把 Week8 收口成 API、Prompt as Code、audit log 和 smoke eval。

这节课解决什么问题


到这一讲，RAG 需要从“能答”收口成“能交付”：

- request schema
- response schema
- citation schema
- prompt files + manifest
- audit log
- smoke eval report

参考学习时间

45—55 分钟

先看一张总图



1. RAG Request 最小字段

```
{  
  "question": "How do I recover an Edge Gateway after firmware upgrade failure?",
```

```

"product_line": "edge-gateway",
"actor_role": "support_agent",
"visibility_scope": "public",
"entitlement_tier": "standard",
"top_k": 5,
"index_release_id": "index-week08-dev",
"data_release_id": "data-week08-dev",
"prompt_release_id": "prompt-week08-v1",
"include_debug": true
}

```

2. Prompt as Code

Prompt 不应该只藏在 notebook 或运行时字符串里。

最小结构：

```

services/rag_api/app/prompts/
  system_v1.md
  answer_v1.md
  no_answer_v1.md
  prompt_manifest.yml

```

prompt_manifest.yml 至少要包含：

- prompt_release_id
- template files
- description
- created_at
- rollback note

3. Audit log 记录什么

字段	为什么要记录
question	复现输入
filters	判断权限和版本边界
retrieved_evidence_ids	复现证据
scores	排查召回/重排问题
answer	复盘输出
confidence / abstain_reason	判断是否该回答
release_id / index_release_id / prompt_release_id	复现版本
latency_ms	观察运行质量

4. Smoke eval 不等于 full eval

Week8 只做最小 smoke eval：

- response schema valid
- answer case 有 citation / evidence_ids

- no-answer case 有 abstain_reason
- release ids present
- filter behavior 可解释

Week11 才做系统化评测、样本集扩展和 LLM-as-judge。

5. 最终 API 调用

```
curl -X POST http://localhost:8000/rag/answer \
-H "Content-Type: application/json" \
-d '{
  "question": "How do I recover an Edge Gateway after firmware upgrade failure?",
  "product_line": "edge-gateway",
  "top_k": 5,
  "index_release_id": "index-week08-dev",
  "prompt_release_id": "prompt-week08-v1",
  "include_debug": true
}'
```

本课最重要判断

RAG API 的交付标准不是“能聊”，而是 response contract、prompt release、citation、audit 和 smoke eval 能共同证明这次回答可追溯。

自检清单

- 我能写出 RAG request / response 的关键字段。
- 我知道 prompt 为什么要文件化和版本化。
- 我能说明 audit log 如何帮助复盘坏答案。
- 我能区分 Week8 smoke eval 和 Week11 full eval。