

## Week02 | 作业 | 资产清单、四类契约 v1 与采集计划

### 本页结构

|                                                         |   |
|---------------------------------------------------------|---|
| 把 Week02 收成一套能进入 Week03 的输入准入包 .....                    | 1 |
| 1. 作业目标 .....                                           | 2 |
| 1.5 这份作业在整门课里的真实价值 .....                                | 2 |
| 2. 参考投入时间 .....                                         | 2 |
| 3. 你要提交什么 .....                                         | 2 |
| A. 资产盘点 .....                                           | 2 |
| B. metadata / PII 设计 .....                              | 2 |
| C. 四类数据契约 .....                                         | 2 |
| D. 采集计划 / manifest .....                                | 2 |
| E. 提交说明 .....                                           | 3 |
| 4. 标准提交树 .....                                          | 3 |
| 5. 提交工件总表 .....                                         | 3 |
| 6. 最低完成标准 .....                                         | 4 |
| 7. 评分 Rubric .....                                      | 4 |
| 8. 优秀 / 合格 / 不合格 分别长什么样 .....                           | 4 |
| 9. 推荐验证方式 .....                                         | 4 |
| 验证命令 1: contract tests .....                            | 4 |
| 验证命令 2: seed loader dry-run .....                       | 4 |
| 10. 审阅者会按什么顺序看你的作业 .....                                | 5 |
| 11. 评审人最看重的 5 件事 .....                                  | 5 |
| 12. 最容易丢分的 8 个点 .....                                   | 5 |
| 13. 一个可直接改写的 <code>submission_readme.md</code> 模板 ..... | 5 |
| 14. 推荐验证方式之外，还可以怎么加分 .....                              | 6 |
| 15. 验收方式 .....                                          | 7 |
| 最低通过线 .....                                             | 7 |
| 更强的完成度 .....                                            | 7 |
| 16. 这页和实验页怎么衔接 .....                                    | 7 |
| 17. 交作业前的 10 项自检 .....                                  | 7 |

### 把 Week02 收成一套能进入 Week03 的输入准入包

这次作业不是把实验再抄一遍，而是把 Week02 的结果整理成一套真正能承接 Week03 ingest 的工程交付物。

你要交的不是“课堂答案”，而是：

- 哪些输入资产值得接入
- 每类输入必须带什么 metadata
- 哪些字段涉及高风险 PII
- 哪些 JSON contract 才能作为运行时 gate
- 这次 ingest 到底接哪一批 source，怎么验证它至少最小可运行

## 1. 作业目标

这次作业要把 Week02 的工件压成一套输入准入包。

你最终交出来的内容，必须回答下面 5 个问题：

1. 哪些资产可以进入系统
2. 每类输入至少要带什么 metadata
3. 哪些字段属于高风险 PII，应该如何处理
4. 哪些 JSON contract 才构成真正的运行时 gate
5. 你的 manifest 和 ingest strategy 如何接到 Week03

### ! 这次作业和实验的区别

实验页解决的是：你能不能把 Week02 的闭环跑起来。

作业页解决的是：你能不能把这套闭环整理成一份可提交、可审查、可进入 Week03 的正式工程包。

## 1.5 这份作业在整门课里的真实价值

这份作业不是 Week02 的结课文件，而是 Week03 的入口准入包。

- Week03 的 ingest admission 会继续消费你在这里定义的 contract 和 manifest。
- Week08 的 retrieval、citation 和 response contract 会继续消费你今天定义的 metadata 与 evidence。
- Week10 的 tool boundary、Week14 的 release / lineage / rollback，也都会建立在这套输入边界之上。

换句话说，评审方不是在收文件，而是在收一套可以被后续系统继续消费的工程输入。

## 2. 参考投入时间

如果你只是阅读作业要求并理解交付结构，大约需要 20—30 分钟；如果你要把蓝图、四类 contract、manifest、ingest strategy 和提交说明真正收成一套可审查的输入准入包，并完成验证，建议预留 4—6 小时。

## 3. 你要提交什么

本次作业所有交付物，都应保留在 repo 的真实路径下。

### A. 资产盘点

- docs/blueprints/week02/asset\_inventory\_v1.csv

### B. metadata / PII 设计

- docs/blueprints/week02/metadata\_minimums\_v1.md
- docs/blueprints/week02/pii\_policy\_matrix\_v1.csv

### C. 四类数据契约

- contracts/data/ticket\_contract.json
- contracts/data/doc\_asset\_contract.json
- contracts/data/audio\_asset\_contract.json
- contracts/data/video\_asset\_contract.json

### D. 采集计划 / manifest

- data/seed\_manifests/manifest\_week02\_practice\_v1.json

- docs/blueprints/week02/ingest\_strategy\_v1.md

## E. 提交说明

- docs/blueprints/week02/submission\_readme.md

## 4. 标准提交树

```
docs/
  blueprints/
    week02/
      asset_inventory_v1.csv
      metadata_minimums_v1.md
      pii_policy_matrix_v1.csv
      ingest_strategy_v1.md
      submission_readme.md
  contracts/
    data/
      ticket_contract.json
      doc_asset_contract.json
      audio_asset_contract.json
      video_asset_contract.json
  data/
    seed_manifests/
      manifest_week02_practice_v1.json
```

## 5. 提交工件总表

| 类别                | 文件路径                                                 | 这份工件回答什么                         |
|-------------------|------------------------------------------------------|----------------------------------|
| 资产盘点              | docs/blueprints/week02/asset_inventory_v1.csv        | 哪些输入值得接入                         |
| metadata 标准       | docs/blueprints/week02/metadata_minimums_v1.md       | 每类输入至少要带什么字段                     |
| PII 规则            | docs/blueprints/week02/pii_policy_matrix_v1.csv      | 哪些字段能进模型、哪些必须拦截                  |
| ticket contract   | contracts/data/ticket_contract.json                  | 工单输入如何被 gate                     |
| document contract | contracts/data/doc_asset_contract.json               | 文档输入如何被 gate                     |
| audio contract    | contracts/data/audio_asset_contract.json             | 音频输入如何被 gate                     |
| video contract    | contracts/data/video_asset_contract.json             | 视频输入如何被 gate                     |
| practice manifest | data/seed_manifests/manifest_week02_practice_v1.json | 这次 ingest 到底接哪一批 source          |
| ingest strategy   | docs/blueprints/week02/ingest_strategy_v1.md         | full / incremental / replay 如何选择 |
| 提交说明              | docs/blueprints/week02/submission_readme.md          | 你改了什么、为什么这么改、如何验证                |

## 6. 最低完成标准

这次作业的最低通过线有 4 条：

1. 至少覆盖四类输入中的两类，推荐四类都覆盖
2. 四类 contract 必须都经过检查，不允许只交一类
3. 至少提供 1 个可工作的 `manifest_week02_practice_v1.json`
4. 必须给出 1 次 contract tests 与 1 次 seed loader dry-run 的验证说明

如果你只交了 Markdown 总结，没有改 repo 中真实的 contract / manifest / blueprint 路径，这次作业不能算完成。

## 7. 评分 Rubric

| 维度                       | 权重 | 重点看什么                                         |
|--------------------------|----|-----------------------------------------------|
| 资产盘点质量                   | 20 | 有没有从资源目录升级为输入地图                               |
| metadata / PII 设计        | 25 | 是否形成字段 × 动作 × 风险矩阵                            |
| 四类 contract 完整性          | 35 | 是否具备 schema + semantics + policy + quality 思维 |
| manifest / 采集计划质量        | 10 | 是否具备运行时意图                                     |
| submission_readme.md 说明力 | 10 | 能否体现你的判断                                      |

## 8. 优秀 / 合格 / 不合格 分别长什么样

| 档位  | 特征                                    |
|-----|---------------------------------------|
| 优秀  | 有完整判断链，能解释 trade-off，能看出 Week03 可直接承接 |
| 合格  | 工件齐全，路径正确，能跑通最小验证                     |
| 不合格 | 只交说明文档，不改真实 repo 工件                   |

## 9. 推荐验证方式

本次作业默认统一走 Docker devbox，不要求本机裸跑。

### 验证命令 1: contract tests

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  pytest tests/contract/ -v
```

### 验证命令 2: seed loader dry-run

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  python -m pipelines.ingestion.seed_loader --manifest-dir data/seed_manifests
```

你需要在 docs/blueprints/week02/submission\_readme.md 里明确记录：

- 你执行了什么命令
- 命令是否成功
- 如果失败，你做了什么修正

## 10. 审阅者会按什么顺序看你的作业

1. 先看 docs/blueprints/week02/submission\_readme.md
2. 再看 docs/blueprints/week02/asset\_inventory\_v1.csv
3. 再看 docs/blueprints/week02/metadata\_minimums\_v1.md 与 docs/blueprints/week02/pii\_policy\_matrix\_v1.csv
4. 再看四类 contract
5. 最后看 manifest\_week02\_practice\_v1.json 和验证结果

## 11. 评审人最看重的 5 件事

| 评审重点                  | 为什么它重要                |
|-----------------------|-----------------------|
| 路径是否 repo-aligned     | 课程工件必须能直接进入项目现实       |
| metadata / PII 是否有判断  | 不是抄字段表，而是真的理解边界       |
| contract 是否具备 gate 意义 | 能不能拦截运行时风险，而不是只描述结构   |
| manifest 是否能接到 Week03 | 不是“随便写一个 JSON”，而是批次入口 |
| 验证记录是否真实              | 没有运行证据，这套工件就还只是纸面设计   |

## 12. 最容易丢分的 8 个点

| 丢分点                                                | 为什么会被扣分                                |
|----------------------------------------------------|----------------------------------------|
| 只交 Markdown，不改 repo 中真实 contract / manifest        | 说明没有把课程结论压进工程结构                        |
| 仍然使用 YAML contract / YAML manifest 作为主交付格式         | 与当前项目现实冲突                              |
| 资产清单只有资源名，没有 owner / access / update / risk        | 还停留在资源罗列层                              |
| PII 只写等级，不给字段级动作矩阵                                 | 没有形成可执行边界                              |
| contract 只有 schema，没有 semantics / quality / policy | 不是 gate，只是字段表                          |
| 采集计划只有“每天跑一次”                                      | 没有声明 full / incremental / replay 的业务语义 |
| 没有提交验证结果                                           | 无法证明最小闭环成立                             |
| submission_readme.md 只写流水账                         | 审阅者看不出你的判断                             |

## 13. 一个可直接改写的 submission\_readme.md 模板

```
# Week02 Submission README
```

```
## 1. 本次覆盖的输入资产
```

- 业务线:
- 资产类型:
- 为什么这些资产进入本次范围:

### ## 2. 关键 metadata 设计

- shared core:
- ticket 特有字段:
- document 特有字段:
- audio 特有字段:
- video 特有字段:

### ## 3. 高风险 PII 与边界判断

- 哪些字段被归为 restricted / sensitive:
- 哪些动作必须拦截:
- 哪些场景允许 warn / quarantine:

### ## 4. Data Contract 设计说明

- 哪些 contract 被修正:
- 哪些字段属于 shape:
- 哪些字段属于 semantics / evidence / policy / quality:
- 哪类变更会被视为 breaking:

### ## 5. Manifest / ingest strategy 说明

- 本次 manifest 对应哪些 source:
- 使用了哪些 load mode:
- 为什么这样设计:

### ## 6. 验证记录

- contract tests 命令:
- contract tests 结果:
- seed loader dry-run 命令:
- seed loader dry-run 结果:

### ## 7. 失败与修正

- 我故意注入了什么失败:
- 它在哪个阶段暴露:
- 我怎么修:

### ## 8. 进入 Week03 前, 我的最终判断

- 已具备的 ingest baseline:
- 仍需 Week03 解决的运行时能力:

## 14. 推荐验证方式之外, 还可以怎么加分

以下内容可以作为加分项, 但不是最低要求:

- 再补 1 个 manifest
- 在 tests/contract/fixtures/week02/ 里增加更多反例
- 清楚说明一个 breaking change 会如何影响 Week03 ingest
- 再加 1 张你自己的输入控制面闭环图

## 15. 验收方式

验收重点不是“你有没有听懂课”，而是你有没有把 Week02 的工件真正整理成一个可以被项目消费的输入准入包。

### 最低通过线

- ☐ 我已经完成 `asset_inventory_v1.csv`
- ☐ 我已经完成 `metadata_minimums_v1.md`
- ☐ 我已经完成 `pii_policy_matrix_v1.csv`
- ☐ 我已经复核并修正四类 JSON contract
- ☐ 我已经完成 `manifest_week02_practice_v1.json`
- ☐ 我已经完成 `ingest_strategy_v1.md`
- ☐ 我已经写出 `submission_readme.md`
- ☐ 我已经跑过一次 `pytest tests/contract/ -v`
- ☐ 我已经跑过一次 `seed_loader dry-run`

### 更强的完成度

- ☐ 我能解释为什么我的 contract 真的具备 gate 意义
- ☐ 我能解释 manifest 与 Week03 ingest 的对应关系
- ☐ 我能说明一次失败应该在 contract tests 还是 seed loader 阶段暴露

## 16. 这页和实验页怎么衔接

实验页解决的是：

- 你能不能把 Week02 的输入控制面跑起来

作业页解决的是：

- 你能不能把这套工件整理成一个正式提交包

所以这页不再重复实验步骤，而是把实验结果收口成：

- 蓝图
- contract
- manifest
- ingest strategy
- 提交说明
- 验证记录

这些东西，就是你进入 Week03 之前的真实工程基线。

## 17. 交作业前的 10 项自检

- ☐ 所有工件都放在 repo 的真实路径，而不是散装附件
- ☐ 我提交的是 JSON contract / JSON manifest，而不是退回到 YAML 主路径
- ☐ `asset_inventory_v1.csv` 不只是资源列表，而是真正的输入地图
- ☐ `metadata_minimums_v1.md` 能解释字段为什么存在、会被谁消费
- ☐ `pii_policy_matrix_v1.csv` 已形成字段 × 动作 × 风险矩阵
- ☐ 四类 contract 都具备 schema 之外的 semantics / policy / quality 判断
- ☐ `manifest_week02_practice_v1.json` 明确声明了 load mode 和 contract binding
- ☐ 我有真实的 `pytest tests/contract/ -v` 验证记录
- ☐ 我有真实的 `seed_loader dry-run` 记录，而不是“理论上应该能跑”

- ☐ 我知道哪些问题属于 Week02 的边界，哪些留给 Week03 继续解决