

Week02 | 输入确定性保障——数据盘点与数据契约

在进入采集、入湖、RAG 与 Agent 之前，先把输入系统做对

这一周不是在补“数据治理附属工作”，而是在建立生产级 AI 系统的第一道主结构：

什么数据可以进入系统、必须带什么元数据、哪些字段需要 PII 管控、什么情况下必须被拦截。

很多团队把 AI 失真归因到模型不够强、Prompt 不够细、检索不够准；但在真实企业场景中，更早摧毁系统的，往往是输入侧的静默漂移、来源不明、口径不一与越权暴露。

本周所有实践默认在 [OmniSupport Copilot 项目仓库](#) 中完成。课程讲义负责解释方法、步骤与判断，代码与验证以项目仓库当前结构为准。

课程里统一使用 Data Contract 这个方法论概念；在当前 OmniSupport Copilot 项目中，Week02 第一版先以 JSON Schema ([contracts/data/*.json](#)) 和 JSON manifest ([data/seed_manifests/*.json](#)) 落地。

本周一句话

把资产盘点、最小元数据、PII 分级、Data Contract 和 source manifest，收口成生产级 AI 系统的输入准入控制面：

什么数据可以进入系统、为什么能进、出了问题怎么被拦、证据能不能回指。

本周要守住的三件事	代表什么
可信	事实不能悄悄漂
可追溯	证据必须能回指
可准入	违规输入必须能拦

本周认知阶梯

阶段	学生要解决什么	对应页面
先建立风险意识	为什么输入先坏而不是模型先坏	课时 1
再做对象建模	哪些资源才值得接入	课时 2
再做最小标准	metadata 与 PII 怎么统一	课时 3
再做门禁	什么输入能放行、什么必须拦截	课时 4
再做批次声明	这一次到底怎么接	课时 5
最后跑闭环	让 contract + manifest 进入工程	实验 / 作业




Figure 1: Week02 认知阶梯：从风险意识、对象建模、最小标准、门禁、批次声明，到工程闭环，最终进入 Week03 ingest。

本周统一案例线：Northstar 三条产品线、四类输入

为了避免每一课都像孤立术语，Week02 全周统一沿着 Northstar 的三个业务场景展开：

产品线	业务场景	本周重点输入
Northstar Workspace	Help Center、FAQ、ticket 处理	ticket、document
Northstar Edge Gateway	PDF 手册、升级说明、故障录像	document、video
Northstar Studio	教程视频、录屏、社区问答、语音支持	video、audio、document

这一周所有判断都围绕四类主输入收口：

- ticket
- document
- audio
- video

这样做的目的不是缩小世界，而是先把最容易进入企业 AI 系统的四类输入对象真正讲透。

本周在整门课里的位置

上承 Week01

接住系统蓝图、Done 边界、风险边界与项目基线。

本周解决

事实是否可信、证据是否能回指、边界是否可执行、输入是否可准入、批次是否可审计。

下接 Week03

把 contract 与 manifest 真正变成 ingest、回放与补数的准入标准。

影响后续

Week07 的证据链、Week08 的 RAG API、Week10 的工具边界、Week14 的版本治理，都会持续消费本周定义的 contract、metadata 与 policy。

本周为什么重要

- 输入问题通常比模型能力不足更早摧毁系统质量。
- 如果 Week02 没有把输入工程化，后面的检索、生成、Agent 和评测都会建立在不稳定基础上。
- 资产盘点不是资源罗列，而是输入系统建模。
- Data Contract 不是说明文档，而是运行时门禁。
- 多模态输入如果没有统一元数据与 PII 分级，后面的引用、过滤、审计都会失真。

本周学习目标

完成这一周后，学员应该能做到：

1. 解释为什么企业 AI 系统首先要解决输入确定性，而不是一上来调模型。
2. 系统盘点结构化、非结构化、音频、视频、工单等输入资产。
3. 设计文档 / 音频 / 视频 / 工单四类最小元数据与 PII 分级规则。
4. 把 Data Contract 写成机器可读、可校验、可拦截的工程门禁。
5. 基于 contract 反推采集策略、增量窗口、失败拦截与 Week03 的 ingest 起跑线。

Week02 的 6 个核心对象，别再混

Week02 最容易学散的原因，是学生会把很多对象混成一句“把数据治理好”。更稳的办法，是先把 6 个核心对象分开，并且知道它们不是谁：

对象	它回答什么问题	不是谁	当前 repo 里的典型落点
<code>source / resource</code>	企业里到底有哪些候选数据源	不是“最终都会进系统的数据”	业务系统、文件系统、音视频源本身
<code>asset inventory</code>	哪些资源值得进入 AI 系统	不是“文件目录”	<code>docs/blueprints/week02/asset_inventory_v1.csv</code>
<code>metadata minimum</code>	每类输入最低要带哪些上下文	不是“备注字段”	<code>docs/blueprints/week02/metadata_minimums_v1.md</code>
<code>PII policy</code>	哪些字段属于什么风险等级、允许什么动作	不是“PII=true/false”	<code>docs/blueprints/week02/pii_policy_matrix_v1.csv</code>
<code>data contract</code>	什么样的记录才算可接收	不是“schema 说明书”	<code>contracts/data/*.json</code>
<code>source manifest</code>	这一次 ingest 到底要接哪一批 source	不是“文件列表”	<code>data/seed_manifests/*.json</code>

把这 6 个对象记清楚之后，Week02 到 Week03 的关系就会稳定很多：

- 课时 2 解决 `asset inventory`
- 课时 3 解决 `metadata minimum + PII policy`
- 课时 4 解决 `data contract`
- 课时 5 解决 `source manifest`
- Week03 再把这 4 件工件推进到 `ingest admission`、`state`、`report`、`replay`

也就是说，Week02 的交付不是“学习材料”，而是 Week03 的准入包。

本周统一方法论：从资源到准入

维度	代表对象	它回答什么
世界里有什么	<code>source / resource</code>	企业真实世界有哪些候选资源
系统准备接什么	<code>asset inventory / metadata / PII</code>	哪些可以成为 AI 输入
本次具体怎么接	<code>contract / manifest / gate</code>	当前批次能不能被系统接收

本周交付物怎么进入 Week03

交付物	当前落点	到 Week03 有什么用
数据资产清单 v1	<code>docs/blueprints/week02/asset_inventory_v1.csv</code>	决定 seed loader 可以考虑哪些 source
Metadata / PII 最小标准	<code>docs/blueprints/week02/metadata_minimums_v1.md</code> 、 <code>pii_policy_matrix_v1.csv</code>	决定进入 ingest 前必须带哪些上下文、哪些字段要拦截或脱敏
四类 Data Contract v1	<code>contracts/data/*.json</code>	决定记录是否能被接收、隔离或拒绝
Source Manifest / 采集计划 v1	<code>data/seed_manifests/*.json</code>	决定这一批 ingest 到底接哪一批 source
输入门禁验证报告	<code>reports/week02/*</code>	作为 Week03 ingest baseline 的起跑证据

本周统一闭环图




Figure 2: Week02 统一闭环图: source/resource 经由 asset inventory、metadata minimum/PII policy、data contract、source manifest，最终进入 Week03 ingest baseline。

这张图最关键的一点是：

Week02 的目标不是“把数据整理得更好看”，而是建立一条输入准入链。

最容易混淆的 5 组概念

1. 资源目录 vs 输入地图

概念	它解决什么	它还没解决什么
资源目录	我们手里有什么	哪些资源真的适合作为 AI 输入
输入地图	哪些输入值得进入系统、如何接、谁负责、影响谁	具体运行时批次策略

2. Schema vs Data Contract

概念	它重点约束什么	为什么不能混用
Schema	字段形状与类型	只解决结构, 不解决语义、边界和运行时动作
Data Contract	结构、语义、质量、权限和兼容性	它决定能不能放行、拦截、报警

3. Contract vs Manifest

概念	它回答什么问题
Contract	一条记录什么样才算合法
Manifest	这一次到底准备接哪一批 source、用什么模式接

4. Quarantine vs Reject

动作	什么时候用
Quarantine	有部分数据还可保留，但必须隔离、等待补救
Reject	当前批次或当前 source 已不满足最低准入条件

5. Metadata vs Provenance

概念	你最该记住什么
Metadata	让系统知道这条内容属于什么、怎样被消费
Provenance	让系统和人能回到“它到底来自哪里、何时产生、谁说的、在哪一页/哪一秒”

! 本周最值得记住的 4 个企业判断

- Data Contract 不是数据字典，而是输入门禁。
- metadata 不是备注，而是运行时接口。
- PII 不是布尔开关，而是字段 × 动作 × 风险矩阵。
- manifest 不是文件列表，而是一次 ingest 的运行时意图声明。

为什么 Week02 不先聊索引与模型

很多团队会问：为什么不先讲 embedding、reranker、Prompt 或索引优化？

因为这些都属于下游表达和排序问题，而 Week02 解决的是上游事实、证据和边界问题。

层面	它主要解决什么
索引 / 模型 / Prompt	下游排序、表达、格式、可读性
输入确定性	上游事实是否可信、证据是否可回指、边界是否可执行

如果上游输入已经漂了，后面再强的模型也只会把错误事实加工得更像真的。

学完 Week02 你应该形成的最小能力闭环

你能说清什么	你能写出什么	你能跑通什么
输入为什么会先毁系统	<code>asset_inventory / metadata / PII / contract / manifest</code>	<code>contract tests + manifest dry-run</code>

五个课时

课时 1 | 为什么输入问题会先于模型问题摧毁系统

这一课先建立核心判断：企业 AI 系统最危险的不是“完全没数据”，而是“数据看起来还能跑，但已经静默偏移”。

重点解决：

- 为什么很多系统不是模型先坏，而是输入先坏
- 三类输入风险如何穿透到检索、生成与动作层
- 为什么 Week02 是整门课的数据入口控制面

[进入课时 1](#)

课时 2 | 从资源目录到输入地图：企业数据资产盘点方法论

这一课把“盘点”从 Excel 清单升级成输入系统建模。

重点解决：

- 怎么盘结构化 / 非结构化 / 对话 / 多模态输入
- 如何识别 owner、refresh、access、risk、consumer
- 如何把盘点结果沉淀成后续 contract 与 ingest 的输入地图

[进入课时 2](#)

课时 3 | 多模态最小元数据与 PII 分级：文档、音频、视频、工单怎么统一

这一课专门解决统一标准问题。

重点解决：

- 文档、音频、视频、工单分别必须保留哪些最小元数据
- provenance、timestamps、speaker_role、page_no、bbox、section_path 为什么是硬约束
- 字段级 PII 分级、脱敏规则、权限边界如何前置到输入层

[进入课时 3](#)

课时 4 | 把 Data Contract 做成工程门禁：Schema、语义、质量、兼容性

这一课把契约从“写文档”升级为“能拦截运行时风险”。

重点解决：

- Schema、业务口径、质量门禁、access policy 如何统一进 contract
- additive / conditional / breaking change 怎么定义
- 为什么 contract 必须进 CI、lint、runtime gate，而不是只放在 Wiki

[进入课时 4](#)

课时 5 | 契约驱动的采集策略：Manifest、增量窗口、拦截与 Week03 起跑线

这一课把 Week02 真正收口到 Week03。

重点解决：

- manifest 怎么驱动 ingest
- 全量、增量、回放、隔离区如何声明化
- schema drift、metadata 缺失、PII 违规如何自动拦截
- 怎么把本周工件转成 Week03 的 ingest baseline

进入课时 5

实验 | 四类数据契约与输入门禁最小闭环

实验目标不是“补几份契约文件”，而是跑通一个最小闭环：

- 为 ticket / document / audio / video 四类输入定义 contract v1
- 为 JSON manifest 定义最小校验规则
- 模拟一次字段漂移或元数据缺失
- 验证 gate 能否正确放行、拦截、隔离并输出报告

进入实验

作业 | 资产清单、四类契约 v1 与采集计划

本周作业要求学员真正交付一套可进入 Week03 的输入准入包：

- 《数据资产清单》v1
- ticket / document / audio / video 四类 contract v1
- 《采集计划 / source manifest》v1
- 一份对 schema 变更、PII 风险、元数据缺失的处理说明

进入作业

本周交付物

- 《数据资产清单》v1
- 《四类 Data Contract》v1
- 《采集计划 / Source Manifest》v1
- 《输入门禁最小闭环验证报告》v1

关键判断

- 输入问题是系统问题，不是辅助治理问题。
- 资产盘点是输入系统建模，不是资源罗列。
- 最小元数据是后续证据链、权限过滤和审计的基础设施。
- Data Contract 只有能放行、能拦截、能预警，才算工程门禁。
- Week02 做得越扎实，Week03 之后的 ingest、RAG、Agent、评测与治理越稳。

上下游关系

- 上承 Week01：把系统蓝图、Done 边界与风险边界压到输入侧。
- 下接 Week03：把 contract、manifest、gate 变成 ingest 的准入标准。
- 影响 Week07—Week14：元数据、证据链、权限、兼容性与版本治理都会持续复用本周定义。

延伸阅读

- Schema 与 Contract Thinking
- Metadata / Provenance / Lineage
- PII Classification 与 Redaction
- Structured Outputs、Citations 与 Tool Boundary