

Week02 | 输入确定性保障——数据盘点与数据契约

教师展示页 | 用于 Week02 总览引入与进入课时 1

本课导航

这周到底在解决什么	1
先看这周的认知阶梯	2
用 Northstar 的三个业务场景把这一周讲透	2
Week02 的 6 个核心对象，先分开再讲透	3
世界里有什么	3
本次具体怎么接	3
为什么这周不先聊索引与模型	3
下游优化	3
上游确定性	3
Week01、Week02、Week03 是一条连续的工程主线	4
本周交付物不是“作业材料”，而是 Week03 的准入包	4
本周统一闭环图	5
进入课时 1 之前，先记住这 4 句话	5
接下来先做本周第一道判断	5

这周到底在解决什么

! 一句话先说清

Week02 不是在补“数据治理附属工作”，而是在建立生产级 AI 系统的输入准入控制面：
什么数据可以进入系统、必须带什么上下文、哪些字段需要 PII 管控、什么情况下必须被拦截。

很多团队一谈到 AI 工程，注意力会立刻落到模型、Prompt、Embedding、Reranker 上。

这些当然重要。

但真正进入企业环境后，更早摧毁系统的，往往不是模型能力，而是输入侧的静默漂移、来源不明、口径不一和越权暴露。

本周要守住的三件事	代表什么
可信	事实不能悄悄漂
可追溯	证据必须能回指
可准入	违规输入必须能拦

先看这周的认知阶梯




Figure 1: Week02 教师总览认知阶梯图

i 这周不是散着学 5 个概念

这周真正要搭起来的是一条链：

source / resource → asset inventory → metadata minimum / PII policy → data contract → source manifest → gate / run evidence

用 Northstar 的三个业务场景把这一周讲透

业务线	典型场景	重点输入	这一周最容易出的问题
Northstar Workspace	Help Center、FAQ、ticket 处理	ticket、document	状态枚举漂移、租户边界不清
Northstar Edge Gateway	PDF 手册、安装说明、故障录像	document、video	layout / provenance 丢失
Northstar Studio	教程视频、录屏、语音支持	video、audio、document	timestamp、speaker_role、PII 处理不足

💡 为什么统一案例线很重要

如果每一课都像独立术语表，学生会记住词，不会形成工程判断。

统一案例线的作用，是让每个对象都能回到真实业务里： – 为什么要保留 `page_no` / `bbox` – 为什么 `speaker_role` / `pii_redaction_flag` 不是备注字段 – 为什么 `contract` 和 `manifest` 必须进入运行时

Week02 的 6 个核心对象，先分开再讲透 世界里有什么

对象	它回答什么问题	不是谁
<code>source / resource</code>	世界里有哪些候选资源	不是“最终都会进系统的数据”
<code>asset inventory</code>	哪些资源值得进入 AI 系统	不是“文件目录”
<code>metadata minimum</code>	每类输入最低需要哪些上下文	不是“备注字段”

本次具体怎么接

对象	它回答什么问题	不是谁
<code>PII policy</code>	什么字段属于什么风险、允许什么动作	不是“PII=true/false”
<code>data contract</code>	什么样的记录才算可接收	不是“schema 说明书”
<code>source manifest</code>	这一次 <code>ingest</code> 到底接哪一批 <code>source</code>	不是“文件列表”

为什么这周不先聊索引与模型 下游优化

- `embedding`
- `reranker`
- `prompt`
- 输出格式

上游确定性

- 事实是否可信
- 证据是否可回指
- 边界是否可执行
- 输入是否可准入
- 批次是否可审计

! 这一周最想建立的判断

如果上游输入已经漂了，下游优化只是在把错误加工得更像真的。

Week01、Week02、Week03 是一条连续的工程主线



Figure 2: Week01 到 Week03 连续工程主线图

周次	真正解决什么
Week01	定边界：系统要做什么、不该做什么
Week02	定准入：什么输入能进、为什么能进、出了问题怎么拦
Week03	跑链路：怎样稳定 ingest、怎样重跑、怎样补数

本周交付物不是“作业材料”，而是 Week03 的准入包

交付物	当前落点	到 Week03 有什么用
数据资产清单 v1	docs/blueprints/week02/ asset_inventory_v1.csv	决定哪些 source 值得接
四类 Data Contract v1	contracts/data/*.json	决定记录能不能放行
Source Manifest / 采集计划 v1	data/seed_manifests/*.json	决定本批次 ingest 接什么
输入门禁验证报告	tests/contract/ + dry-run 结果	决定问题如何暴露、拦截与回放

本周统一闭环图




Figure 3: Week02 教师总览统一闭环图

i 请带着这张图学完整个 Week02

因为这一周的目标不是“把数据整理得更规范”，而是建立一条输入准入链。

进入课时 1 之前，先记住这 4 句话

1. Data Contract 不是数据字典，而是输入门禁。
2. metadata 不是备注，而是运行时接口。
3. PII 不是布尔开关，而是字段 × 动作 × 风险矩阵。
4. manifest 不是文件列表，而是一次 ingest 的运行意图声明。

接下来先做本周第一道判断

! 进入课时 1

为什么输入问题会先于模型问题摧毁系统？

如果这个判断立不住，后面的 asset inventory、metadata、PII、contract、manifest 都会被误解成“治理附属动作”。

[进入课时 1 教师页](#)