

Week04 | 作业 | Week04 Lakehouse 最小交付包与 baseline report

本页结构

把 Week04 收口成一套可交接、可复核、可继续扩展的最小交付包	1
这次作业真正要交付什么	1
建议投入时间	2
最终必交工件	2
Week04 在项目里的位置	2
与真实项目实现对齐	3
这次作业最重要的边界	3
七项任务	4
任务 1: 写清 Lakehouse foundation	4
任务 2: 完成 source-to-Iceberg mapping	4
任务 3: 完成最小 4 表设计	4
任务 4: 完成 catalog runtime plan	4
任务 5: 提交 baseline report	4
任务 6: 整理 runbook	5
任务 7: 补齐验证证据	5
评分 Rubric	5
优秀 / 合格 / 不合格边界	6
不接受的作业类型	6
提交格式	6
优秀样例应该具备什么	7
推荐目录结构	7
完成标准	7
与 Week05 的衔接	7
最后的收尾判断	7

把 Week04 收口成一套可交接、可复核、可继续扩展的最小交付包

这份作业不是把实验页再机械重跑一遍，而是要求你把 Week04 真正交付成一套：

可解释、可回看、可演进、可验收 的 Lakehouse 基线包。

这次作业真正要交付什么

Week04 到这里，课程已经把这些判断讲清楚了：

- 为什么需要有记忆的表；
- Iceberg 的状态模型是什么；
- 最小 4 表应该怎样落；
- 本地最小闭环怎样跑；
- baseline 应该怎样看。

这次作业不是再演示一遍命令，而是要把这些内容整理成团队可交接交付物。


建议投入时间

建议按半天作业安排：先整理实验输出，再补齐设计说明、runbook 和评分自查。

最终必交工件

工件	文件/截图/报告	合格标准	常见不合格原因
ADR / Foundation	<code>docs/blueprints/week04/lakehouse_foundation_v1.md</code>	目标、边界、为什么需要表状态记忆讲清楚	写成 Iceberg 百科，没有项目判断
source-to-Iceberg mapping	<code>docs/blueprints/week04/source_to_iceberg_mapping_v1.md</code>	source、target、transform、required、note 齐全	自己发明字段，和 repo schema 不一致
4 表物化记录	<code>reports/week04/materialization_report.json</code>	4 表范围、row count、write mode、snapshot 证据可复核	只有 create table, 没有真实写入
time travel 记录	<code>reports/week04/time_travel_demo_report.md</code>	有 snapshot id、old/current 对比和结论	只说“能 time travel”，没有证据
schema evolution 记录	<code>reports/week04/schema_evolution_demo_report.md</code>	只做 add column, 说明兼容性边界	扩展到 rename/drop 但无治理说明
baseline report	<code>reports/week04/iceberg_baseline_report.md</code>	指标、异常、建议完整	只有截图或命令，无判断
runbook	<code>runbooks/week04/README.md</code>	别人能按步骤复现并排错	只贴命令，不写前置与失败处理
课程同步包	<code>docs/blueprints/week04/course_site_sync_packet_v1.md</code>	课程页命令与项目 runbook 一致	页面、runbook、实际模块三者漂移
测试证据	Week04 contract / integration tests 输出	能证明 schema、catalog、dry-run、time travel、baseline 都可检查	只跑页面，不跑项目验证

Week04 在项目里的位置



与真实项目实施对齐

本次作业以 dataPro-lgtm/omnisupport-copilot 的 Week04 主线为准, 不再使用占位命令。你提交时要能说明:

对齐点	项目路径 / 命令	作业里要体现什么
主执行路径	runbooks/week04/README.md	按 devbox CLI 跑, 不把 Dagster 当主写入路径
环境契约	<code>python -m pipelines.lakehouse.settings --check</code>	catalog、warehouse、MinIO endpoint 配置可解释
Catalog smoke	<code>python -m pipelines.lakehouse.catalog --smoke</code>	bucket、namespace、4 表可 ensure
物化	<code>python -m pipelines.lakehouse.materialize --all-core --report-json reports/week04/materialization_report.json</code>	4 表 row count、write mode、snapshot_id 可复核
Inspection	<code>python -m pipelines.lakehouse.inspect_metadata --table silver.ticket_fact --view snapshots</code>	inspect_metadata / history / files 至少覆盖一张核心 Silver 表
Time travel	<code>python -m pipelines.lakehouse.demo_cli_time_travel --table silver.ticket_fact --out reports/week04/time_travel_demo_report.md</code>	有旧状态与当前状态对比
Schema evolution	<code>python -m pipelines.lakehouse.demo_cli_schema_evolution --table bronze.raw_doc_asset --add-column source_checksum_algo --out reports/week04/schema_evolution_demo_report.md</code>	只做 add-column, 并说明兼容性边界
Baseline	<code>python -m pipelines.lakehouse.demo_cli_iceberg_baseline --all-core --out reports/week04/iceberg_baseline_report.md</code>	形成可交接 baseline report

这次作业最重要的边界

! 不要把 Week04 做成 Week05+

这次作业不要求:

- dbt / semantic layer 主实现;
- Gold mart 全量设计;
- RAG 主链路;
- 重型基础设施引入;
- compaction / cleanup 的完整生产 pipeline。

它只要求你交付 Week04 自己的最小闭环和正式交付包。

七项任务

任务 1: 写清 Lakehouse foundation

lakehouse_foundation_v1.md 至少回答:

- Week04 解决什么问题;
- 为什么 Week03 ingest baseline 还不够;
- 为什么要建立 table state reproducibility;
- 本周做什么、不做什么;
- 后续 Week05 / Week06 / Week08 如何消费这个结果。

任务 2: 完成 source-to-Iceberg mapping

source_to_iceberg_mapping_v1.md 至少包含:

source	source field	target table	target column	type rule	semantic note
ticket	待补	bronze.raw_ticket_event	待补	待补	待补

不要随意发明字段。真实字段以项目仓库的 source schema、`pipelines/lakehouse/iceberg_schemas.py` 和 Week02 contract 为准。

任务 3: 完成最小 4 表设计

bronze_silver_table_design_v1.md 至少说明:

- `bronze.raw_ticket_event` 的角色;
- `bronze.raw_doc_asset` 的角色;
- `silver.ticket_fact` 的角色;
- `silver.knowledge_doc` 的角色;
- Bronze 保真与 Silver 统一如何分工;
- hidden partitioning 的初始判断;
- 为什么不提前做 Gold / evidence anchor。

任务 4: 完成 catalog runtime plan

catalog_runtime_plan_v1.md 至少说明:

- 为什么选 Pylceberg;
- 为什么用 PostgreSQL-backed SQL Catalog;
- 为什么用 MinIO warehouse;
- catalog / warehouse / table location 如何拆开;
- CLI 与 Dagster thin wrapper 的边界;
- 为什么当前学生主路径是 devbox CLI, 而不是 Dagster 直接写 Iceberg。

任务 5: 提交 baseline report

iceberg_baseline_report.md 至少包含:

- 表名;
- 当前数据规模;
- snapshot 状态;
- 文件状态;
- 分区状态;
- latest snapshot time;

- time travel demo 结果；
- schema evolution demo 结果；
- 异常点；
- 下一步建议。

任务 6：整理 runbook

[runbooks/week04/README.md](#) 至少覆盖：

- 环境准备；
- catalog 检查；
- warehouse 检查；
- ensure table；
- materialization；
- inspection；
- time travel；
- schema evolution；
- baseline report；
- 常见失败与排查。

任务 7：补齐验证证据

至少跑通或解释下面两类验证：

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
    pytest tests/contract/test_week4_iceberg_schema_contract.py -v
```

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
    pytest tests/integration/test_week4_catalog_smoke.py \
    tests/integration/test_week4_lakehouse_smoke.py \
    tests/integration/test_week4_time_travel.py \
    tests/integration/test_week4_perf_baseline.py -v
```

如果因为本地资源或 Docker 状态导致无法完整运行，你需要在提交说明里写清楚失败点、错误信息和下一步修复路径。

评分 Rubric

维度	优秀	合格	不合格
边界意识	能解释 Week4 做什么、不做什么，以及为什么不抢跑	基本列出 Week4 边界	把 dbt / RAG / Gold / governance 当主交付
可复现性	命令、输入、输出、失败排查都能让同学复现	有主要命令和报告	只有截图或口头成功
表设计说明	4 表角色、业务键、技术键、分区边界都清楚	4 表角色基本清楚	表边界混乱或字段自造

维度	优秀	合格	不合格
time travel 证据	有 snapshot_id、对比结果和结论	有旧状态回看记录	没有可复核证据
baseline 质量	指标、异常、建议、后续衔接完整	记录主要指标	只有数字，没有解释
runbook 可执行性	另一个同学可按 runbook 接手	基本可运行	命令散落、缺少前置与排错
与项目主线一致性	明确对齐 Week02/03/04/05 边界和 omnisupport-copilot 真实 runbook	基本对齐	另起一套命名或路径
验证证据	contract / integration tests 或等价输出齐全	有主要 smoke 输出	没有测试或失败原因说明

优秀 / 合格 / 不合格边界

等级	表现
优秀	有设计、有证据、有 baseline、有失败排查，能清楚解释为什么不抢跑
合格	交付物齐全，能覆盖 4 表、snapshot、time travel、schema evolution、baseline
不合格	只有截图不解释；只有命令无结果；没有 baseline；跳去做 RAG / dbt 但 Week04 闭环没跑通

不接受的作业类型

- 只截图不解释；
- 只贴命令无结果；
- 没有 baseline report；
- 抢跑 RAG / dbt，但 Week4 闭环没跑通；
- 自己发明一套与 repo 不一致的字段和路径；
- 复制旧课程页命令，但没有对齐当前项目 runbook。

提交格式

建议按目录提交 Markdown 报告、命令日志和 baseline report。截图可以作为辅助证据，但不接受“只贴截图不解释”的作业。

提交说明至少包含：

- 本次使用的 repo commit；
- 使用的 data batch / manifest；
- catalog 与 warehouse 配置来源；
- 真实命令来自哪个 runbook；
- 哪些命令按 runbook 跑通，哪些因为环境原因没有跑通；
- 失败点、绕过方式与后续风险。

优秀样例应该具备什么

优秀作业通常有这些特征：

- 能解释为什么选当前 catalog / warehouse；
- 能说明最小 4 表的边界；
- 能给出 snapshot_id 和对比结果；
- baseline report 有结论，而不是只有指标；
- runbook 真的能让另一个同学复现；
- 明确说明哪些内容留给 Week05、Week08 或 Week14。

推荐目录结构

```
docs/blueprints/week04/  
  lakehouse_foundation_v1.md  
  source_to_iceberg_mapping_v1.md  
  bronze_silver_table_design_v1.md  
  catalog_runtime_plan_v1.md
```

```
runbooks/week04/  
  README.md
```

```
reports/week04/  
  materialization_report.json  
  time_travel_demo_report.md  
  schema_evolution_demo_report.md  
  iceberg_baseline_report.md
```

```
docs/blueprints/week04/  
  course_site_sync_packet_v1.md
```

完成标准

这次作业真正的通过标准是：

1. 你能交付一套和当前项目结构一致的 Week04 基线包。
2. 你能清楚解释为什么只做最小 4 表和 baseline，不抢跑 Week05+。
3. 你能说清当前 Dagster / CLI / runtime 的边界，而不是模糊带过。
4. 你能提供可以被别人复核的 baseline report。

与 Week05 的衔接

Week05 会基于本周 Silver 表继续 transform 和语义层设计。

它不会回头替你补：

- source-to-iceberg mapping；
- Bronze / Silver 表状态；
- snapshot / time travel 记录；
- baseline report；
- Week04 runbook。

最后的收尾判断

如果只记住一句话，就记这句：

Week04 交付的不是“会用 Iceberg”，而是一套以后能支撑 release-aware 数据系统的最小状态记忆层。