

Week06 | 作业 | 提交 Data Factory v1: 一张资产图、一次精准回填、一份运行证据、一份可交接 Runbook

本页结构

把 Week06 收口成一套能交接的数据工厂交付包	1
这次作业真正要交付什么	1
建议投入时间	1
最终必交工件	2
Week06 在项目里的位置	3
评分边界	3
评分 Rubric	3
可观察证据	4
完成标准	5
作业提交前自检	5
不接受的作业类型	5
建议交付结构	5
week06_delivery_summary.md 最少回答什么	6
优秀 / 合格 / 不合格样例	6
本周工件会被谁继续使用	7
加分项	7
延伸阅读	7
最后的收尾判断	7

把 Week06 收口成一套能交接的数据工厂交付包

这份作业不是考你会不会点 Dagster UI，也不是让你堆几张运行截图。

它真正考的是：你能不能把一次数据链路运行，整理成别人能复核、能恢复、能检查、能交接的工程资产。

这次作业真正要交付什么

Week06 到这里已经把这些判断讲清楚：

- 脚本跑通不等于数据产品可运营。
- asset graph 是运行边界，不是装饰图。
- partition / backfill 必须基于明确窗口。
- checks 和 evidence 决定下游能不能消费。
- runbook 是团队交接接口，不是作者自述。

所以这次作业的最低要求是：交付一个最小但真实的 Data Factory v1，让另一个同学不依赖你本人，也能判断这条链路能不能继续消费。


建议投入时间

按课程统一节奏完成即可。建议预留 4—6 小时：先补齐工件，再跑一遍 evidence / checks 验证，最后写 [week06_delivery_summary.md](#)。

最终必交工件

工件	最低合格标准	常见不合格
Blueprint: <code>docs/blueprints/week06/week06-data-factory-blueprint.md</code>	写清 Week06 scope / non-goals, 说明它不重写 Week03–Week05, 也不抢跑 Week07/08/14	只复制课程文字, 没有项目边界
Asset graph: <code>docs/blueprints/week06/week06-asset-graph.md</code>	至少 5 个关键 asset, 包含 source、factory、partitioned asset、evidence、optional 节点	只有 Dagster UI 截图, 没有 asset key、owner、upstream/downstream
Partition strategy: <code>docs/blueprints/week06/week06-partition-backfill-strategy.md</code>	写清 daily partition、默认 2026-04-17、dry-run backfill 边界	一失败就全量重跑, 没有 partition window
Evidence schema: <code>contracts/run_evidence/week06_run_evidence_schema.json</code>	contract test 通过, required / optional 字段边界清楚	字段缺失、enum 值随意写、optional 当 required
Backfill record: <code>reports/week06/backfill/*.json</code>	有 <code>partition_key</code> 、window、gap reason、idempotency guard、downstream impact	没有 report path, 或者只写“已回填”
Checks summary: <code>reports/week06/asset_checks_summary.md</code>	5 类 checks 有结果: manifest、row count、duplicate/idempotency、required fields、partition completeness	只写“跑过”, 没有结果、reason code 或处理动作
Run evidence: <code>reports/week06/run_evidence/*.json</code>	schema pass, 并写清 downstream decision	optional 依赖 fake passed, <code>reason_codes</code> 类型错误
Runbook: <code>runbooks/week06-data-factory.md</code>	另一个人能照做 UI / CLI 两条路径定位、补数、验证和交接	作者自述型文档, 只写“重跑一下”
Delivery summary: <code>reports/week06/week06_delivery_summary.md</code>	写清结论、限制、证据路径、下一步	空泛总结, 没有任何可复核路径

Week06 在项目里的位置



这张图要让你看懂一个判断：Week06 不是把前几周重做一遍，而是把前几周的输入、表状态、指标和证据组织成可被后续消费的资产边界。后续周次拿到的不是“某个人说跑过”，而是 asset graph、checks、run evidence 和 runbook。

评分边界

! 不要把 Week06 做成平台秀

这次作业不要求：

- Dagster+ 专有功能
- 完整 dynamic / multi partitions
- OpenLineage / OpenMetadata / lakeFS 平台
- Week07 文档解析
- Week08 RAG indexing
- Week10 tool / HITL 主实现
- Week14 完整治理平台

它要求的是：

在当前项目结构里交付一个最小但真实的数据工厂运行边界。

评分 Rubric

维度	高质量：能独立交接	合格：能说明并复现主要路径	需要重做：只有截图或口头描述
Asset graph	asset key、group、owner、upstream/	至少 5 个关键 asset 清楚，依赖关系基本正确	只有 UI 截图，没有资产卡和依赖说明

维度	高质量：能独立交接	合格：能说明并复现主要路径	需要重做：只有截图或口头描述
	downstream、optional 节点都能解释，并有文档路径		
Partition / backfill	默认 daily partition、2026-04-17、dry-run plan、gap reason、idempotency guard 都可复核	能生成 backfill plan, 并说明为什么不全量重跑	一失败就全量重跑，或没有 partition window
Checks	5 类 checks 都有结果、reason code、失败处理动作	5 类 checks 基本覆盖，少量说明可再打磨	只说“跑过”，没有 check report
Evidence	JSON schema 通过，report_path 真实，downstream decision 明确	evidence 字段基本完整，能说明下游是否继续	schema 不通过、字段缺失、optional fake passed
Runbook	另一个同学能按 UI / CLI 两条路径复现定位、补数、验证和交接	核心命令和判断路径可复现	只有作者本人能看懂
后续周衔接	写清 Week07 / Week08 / Week11 / Week14 消费什么证据和限制	能说明主要下游消费点	抢跑解析、RAG、治理平台，或没有交接意识

可观察证据

助教评分时会优先看这些证据，而不是看你写得不多：

可执行：已与项目 runbook 对齐

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  pytest tests/contract/test_week06_run_evidence_schema.py -q
```

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  pytest tests/integration/test_week06_definitions_loadable.py -q
```

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  python -m pipelines.data_factory.backfill_plan --partition 2026-04-17 --mode dry-run
```

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  pytest tests/integration/test_week06_asset_checks.py tests/integration/
test_week06_run_evidence_generation.py -q
```

完成标准

1. asset graph 命名清楚，使用 `week06/*` 或等价 namespace。
2. source observation 与 core materialization job 边界清楚。
3. daily partition strategy 写清楚，不默认全量重跑。
4. backfill / replay 演示有 plan、reason code 和结果记录。
5. 至少 5 类 asset checks 有结果或可执行设计。
6. run evidence schema 区分 required / optional。
7. Week04 / Week05 未启用时写 `skipped` / `not_available`，不 fake passed。
8. runbook 能让另一个人照着完成定位和补数。

作业提交前自检

- ☐ 我能说清每个 asset key 的 owner、upstream、downstream。
- ☐ 我能解释为什么默认 daily partition。
- ☐ 我有一份 `2026-04-17` 的 backfill dry-run plan。
- ☐ 我跑过 run evidence schema test。
- ☐ 我没有把 optional 依赖写成 `passed`。
- ☐ 我写清了 downstream decision。
- ☐ 我的 runbook 不是只有我本人能看懂。
- ☐ 我写清了已知限制。

不接受的作业类型

- 只有 Dagster UI 截图，没有 artifact 路径。
- 只有文字总结，没有 backfill plan、checks、run evidence。
- 没有 `contracts/run_evidence/week06_run_evidence.schema.json` 或 schema 不可校验。
- Week04 / Week05 没跑却写成 `passed`。
- 抢跑 Week07 解析、Week08 RAG、Week10 tool / HITL 或 Week14 完整治理平台。
- runbook 只写“重跑一下”，没有判断树和验收点。
- 把 destructive delete 当成回填演示。

建议交付结构

```
docs/blueprints/week06/  
  week06-data-factory-blueprint.md  
  week06-asset-graph.md  
  week06-partition-backfill-strategy.md  
  week06-run-evidence-spec.md  
  
contracts/run_evidence/  
  week06_run_evidence.schema.json  
  
runbooks/  
  week06-data-factory.md  
  
reports/week06/  
  backfill/  
  checks/  
  run_evidence/  
  asset_checks_summary.md
```

run_evidence_summary.md
week06_delivery_summary.md

week06_delivery_summary.md 最少回答什么

- 这次 Data Factory v1 覆盖哪些 assets?
- 哪些 assets 是 materializable, 哪些是 optional / external?
- 默认 partition strategy 是什么?
- 演示了哪个 failed / missing partition?
- 选择 retry / replay / backfill / dry-run 的原因是什么?
- checks 结果是什么?
- run evidence 路径是什么?
- 下游是否允许继续消费?
- 哪些能力留给 Week07 / Week08 / Week11 / Week14?

建议模板:

```
# Week06 Delivery Summary

## 1. Assets Covered
- core materializable assets:
- external / optional assets:

## 2. Partition and Backfill Decision
- default partition:
- gap reason:
- selected action:
- idempotency guard:

## 3. Checks and Evidence
- checks summary path:
- run evidence path:
- downstream decision:

## 4. Known Limitations
- Week04 optional state:
- Week05 optional state:
- deferred to later weeks:
```

优秀 / 合格 / 不合格样例

等级	具体表现
优秀	报告路径真实; 5 类 checks 有结果; reason code 清晰; run evidence schema 通过; runbook 能让他人复现; summary 明确写出 unblock / hold / dry-run-only
合格	核心路径和证据完整, 能生成 dry-run plan 和 evidence; 图或说明还有打磨空间; optional 状态诚实记录

等级	具体表现
不合格	只有 Dagster 截图；没有 evidence schema；没有 backfill plan；命令不可复现；把未启用依赖写成 <code>passed</code>

本周工件会被谁继续使用

本周作业工件	后续谁会用	用来做什么
<code>reports/week06/run_evidence/*.json</code>	Week07	判断解析输入是否准入
<code>reports/week06/asset_checks_summary.md</code>	Week08	判断索引输入是否可消费
<code>docs/blueprints/week06/week06-asset-graph.md</code>	Week11	评测定位输入边界和失败归因
<code>runbooks/week06-data-factory.md</code>	Week14	治理、回滚、追责和审计复盘

加分项

- 给 asset graph 增加 owner、domain、sensitivity、freshness 字段。
- 补一个 source observation job 与 core materialization job 的对比说明。
- 为 Week04 lakehouse 和 Week05 semantic mart 写清 optional observation 逻辑。
- 给 recovery decision tree 增加实际 case。
- 把 evidence summary 同步到 runbook 的 operator checklist。

延伸阅读

- [Dagster Assets](#)¹
- [Dagster Asset Checks](#)²
- [Dagster Partitions and Backfills](#)³
- [OpenLineage Object Model](#)⁴
- 项目 Week06 runbook: `runbooks/week06-data-factory.md`
- 项目 Week06 sync notes: `reports/week06/course_site_sync_notes.md`

最后的收尾判断

如果只记住一句话，就记这句：

Week06 交付的不是“我会点 Dagster”，而是一套能让数据链路被团队运营、补数、检查和交接的资产化系统。

¹Dagster 官方 Assets 文档用于理解 asset graph、asset key、materialization 和依赖边界。

²Dagster Asset Checks 文档用于理解 checks 为什么是资产质量闸门，而不是普通测试日志。

³Dagster Partitions and Backfills 文档用于理解 daily partition、backfill 和恢复操作的边界。

⁴OpenLineage object model 用于理解 run、job、dataset 和 lineage 证据如何跨系统表达。