

Week 7 | 作业 | 提交文档资产 v1 与质检报告

本页结构

把 Week7 收口成可交接的文档资产交付包	1
作业目标	1
参考完成时间	1
必交工件	1
每个工件最容易漏什么	2
sections / chunks / anchors 样例要求	2
任务 1: schema / contract	3
任务 2: 解析输出	3
任务 3: chunk / anchor	3
任务 4: 50+ 抽样质检	3
任务 5: Week8 ready gate	3
加分项	4
评分标准	4
常见扣分项	4
提交格式	5
作业提交模板	5
自查 checklist	6
作业最重要判断	6
延伸阅读	6
Footnotes	6

把 Week7 收口成可交接的文档资产交付包

这次作业不是提交一批 chunks。

你要提交的是一套能让 Week8 安全消费的文档资产 v1:

schema 清楚、解析可复现、chunk 可回归、anchor 可回指、quality gate 可解释。

作业目标

完成一份 Week7 正式交付包，证明你能把非结构化文档从 raw asset 推进到 Week8-ready document asset。

参考完成时间

按课程统一节奏完成即可。重点是把 schema、样例、质量报告和 Week8 handoff 打包成可验收交付。

必交工件

工件	文件建议	说明
Week7 执行蓝图	docs/blueprints/week07/week07-execution-blueprint.md	写清做/不做边界、路线和风险

工件	文件建议	说明
schema 校验结果	<code>reports/week07/schema_validation_summary.md</code>	覆盖 section / chunk / anchor / parse_run / quality_sample
解析输出样例	<code>artifacts/week07/sections.json</code>	至少包含 2 类文档或说明样本限制
chunk 输出样例	<code>artifacts/week07/chunks.json</code>	使用 <code>section_aware_v1</code>
evidence anchors	<code>artifacts/week07/evidence_anchors.json</code>	每个 chunk 至少一个 anchor
质量报告	<code>reports/week07/chunk_quality_report.md</code>	包含自动指标与抽样清单
Week8 gate	<code>reports/week07/week8_ready_gate.json</code>	明确 pass / warn / fail 与消费规则
bad case 复盘	<code>reports/week07/bad_case_review.md</code>	说明一个解析或切片问题、影响和修复建议

每个工件最容易漏什么

工件	最容易漏	导致的问题
执行蓝图	不写 non-goals	把 Week7 做成 Week8 检索实验
schema 校验结果	只放成功截图, 不放 invalid case	无法证明 contract 真能拦截坏输入
sections	缺 <code>section_path</code> 或 <code>bbox_missing_reason</code>	chunk 继承上下文和 citation 不稳
chunks	用随机 ID 或没有策略版本	策略回归和坏案例比对失败
anchors	只写 URL, 不写 fingerprint / page / section	引用无法锁定真实证据
quality report	只写 pass, 不写 warning / sample_shortfall	下游误以为所有内容可索引
Week8 gate	没有 consumption rule	Week8 不知道哪些 chunk 可用、哪些要隔离

sections / chunks / anchors 样例要求

样例	必须能看出什么
<code>sections.json</code>	<code>section_id</code> 、 <code>section_path</code> 、 <code>section_type</code> 、 <code>page_no</code> 、 <code>bbox</code> 或 <code>bbox_missing_reason</code> 、 <code>source_fingerprint</code>
<code>chunks.json</code>	稳定 <code>chunk_id</code> 、 <code>section_id</code> 、 <code>chunk_strategy_version</code> 、继承 metadata、非空 content、quality flags
<code>evidence_anchors.json</code>	<code>anchor_id</code> 、 <code>chunk_id</code> 、 <code>source_id</code> 、 <code>doc_id</code> 、 <code>doc_version</code> 、page/bbox/source 回指能力

任务 1: schema / contract

补齐或说明以下 schema:

- `knowledge_section.schema.json`
- `document_chunk.schema.json`
- `evidence_anchor.schema.json`
- `parse_run.schema.json`
- `chunk_quality_sample.schema.json`

必须保留字段:

`source_fingerprint`、`doc_version`、`page_no`、`bbox`、`bbox_missing_reason`、`section_path`、`license_tag`、`content_type`、`parse_strategy_version`、`chunk_strategy_version`、`quality_flags`、`pii_flag`、`data_release_id`、`trace_id`。

任务 2: 解析输出

使用 Docling-first 路线生成 normalized sections。

要求:

- 原始输入优先来自 MinIO `s3://omni-raw-documents/...`
- 对读取到的 raw bytes 重新计算 `source_fingerprint`
- 指纹不一致时不能继续
- OCR 默认关闭
- 解析报告要写清 parser capability

任务 3: chunk / anchor

使用 `section_aware_v1`:

- 不允许把纯固定长度切片作为主路径
- overlap 只允许在同一 section 内使用
- 表格默认不拆散
- 每个 chunk 必须有稳定 `chunk_id`
- 每个 chunk 至少有一个 evidence anchor

任务 4: 50+ 抽样质检

如果本地文档不足 50 份, 你仍然要提交:

- 当前样本数
- `sample_shortfall`
- 扩展到 50+ 文档时的抽样流程
- 当前样本的自动指标
- 人工抽样复核清单

任务 5: Week8 ready gate

`week8_ready_gate.json` 至少要说明:

- gate status: PASS / WARN / FAIL
- ready chunks 数量
- blocked chunks 数量

- hard failures
- warnings
- Week8 consumption rule
- parse / chunk strategy version

加分项

- Unstructured fallback 对比，但不改变 Student Core 默认路线。
- OCR optional 路线说明，但不强制学员依赖。
- visual element placeholder schema。
- chunk strategy regression 对比。

评分标准

维度	权重	判断方式
contract completeness	15%	section / chunk / anchor / parse_run / quality_sample schema 是否覆盖关键字段
section normalization	15%	section_path、section_type、page、bbox、parser capability 是否清楚
chunk quality	20%	section_aware_v1 、稳定 ID、表格/步骤/错误码边界是否合理
anchor coverage	20%	每个 chunk 是否都有可回指原文的 evidence anchor
Week8 ready gate	15%	pass / warn / fail / quarantine 和消费规则是否可解释
bad case analysis	10%	是否能说明问题、影响、修复或隔离动作
boundary discipline	5%	是否避免抢跑 Week8、云依赖过重和 LLM citation

常见扣分项

扣分项	为什么扣分
只提交 chunks，没有 sections / anchors	不是可追溯 document asset
PDF chunk 没有 page_no	Week8 citation 基本条件缺失
bbox 缺失但没有 bbox_missing_reason	无法区分 not applicable 与 parser 丢信息
用随机 UUID 做 chunk_id / anchor_id	无法稳定回归
fallback parser 没有 warning	误导下游以为结构保真
在 Week7 里做 embedding / pgvector / RAG API	课程边界错误

bad case review 只写“已修复”

没有说明根因、影响和防复发动作

提交格式

```
docs/blueprints/week07/  
artifacts/week07/  
reports/week07/  
runbooks/week07-unstructured-data.md
```

作业提交模板

```
# Week07 Delivery Summary
```

```
## 1. Scope Boundary
```

- 本周做了什么：
- 明确不做什么：
- Week8 handoff 边界:

```
## 2. Source Inputs
```

- manifest：
- raw object / fallback：
- source fingerprint：
- parser backend：
- parse strategy：
- chunk strategy：

```
## 3. Contract Evidence
```

- schema validation summary：
- invalid fixture result：

```
## 4. Output Evidence
```

- sections：
- chunks：
- evidence anchors：
- quality samples：

```
## 5. Quality Gate
```

- status：
- ready chunks：
- blocked chunks：
- warnings：
- hard failures：
- Week8 consumption rule：

```
## 6. Bad Case Review
```

- bad case：
- root cause：
- downstream impact：
- fix / quarantine：
- status：

```
## 7. Limitations and Next Steps
```

- sample_shortfall:
- parser capability limits:
- OCR / bbox limits:
- Week8 next action:

自查 checklist

- schema 校验通过，且 invalid fixture 能失败。
- sections.json 能解释文档层级与 page/bbox 状态。
- chunks.json 使用 section_aware_v1，没有空 chunk 和孤儿 chunk。
- 每个 chunk 至少有一个 evidence anchor。
- chunk_quality_report.md 包含 metadata completeness、anchor coverage、page/bbox coverage、empty/orphan/duplicate、PII heuristic 和 sample_shortfall。
- week8_ready_gate.json 明确哪些 chunks 可以索引，哪些需要隔离。
- bad_case_review.md 至少复盘一个真实或可复现坏案例。
- 全文没有把 Week7 写成 embedding、pgvector、hybrid retrieval 或 RAG API 实验。

作业最重要判断

Week7 交付不是“生成了多少 chunks”，而是：

Week8 是否可以放心消费这些 chunks，并且每个答案引用都能回到真实原文证据。

延伸阅读

- Docling docs: <https://docling-project.github.io/docling/>。用于解释解析路线和能力边界。
- DoclingDocument: https://docling-project.github.io/docling/concepts/docling_document/。用于对齐 parsed document、section、table、provenance。
- Unstructured elements: <https://docs.unstructured.io/open-source/concepts/document-elements>。作为 optional fallback 的对象模型参考。
- JSON Schema: <https://json-schema.org/understanding-json-schema/>。用于检查作业里的 schema 和 invalid fixture 是否真的有约束。
- OpenAI Structured Outputs: <https://platform.openai.com/docs/guides/structured-outputs>。作为 Week8 预习，理解结构化 citation response 的消费方式。

Footnotes

1. 作业可以提交 warning，但必须解释 warning 对 Week8 消费的影响。
2. 不能为了让作业好看而把 fallback、sample_shortfall、bbox 缺失写成成功。
3. Week7 的作业不接受 embedding、pgvector 或 RAG API 作为替代交付。
4. week8_ready_gate.json 是交接文件，不是装饰文件；它必须能指导 Week8 是否索引。