

Week 7 | 课时 1 | 为什么“抽出文本”不等于非结构化数据工程

本课导航

不是把 PDF 变成文本，而是把文档变成可追溯的数据资产	1
这节课解决什么问题	1
先用大白话讲	2
技术内涵：非结构化数据工程到底工程化了什么	2
外延边界：这节课不讲什么	2
参考学习时间	3
学完这一讲，你应该能做到什么	3
本课产出	3
先看一张总图	3
1. “抽出文本”为什么不够	3
2. Week7 的对象边界	4
3. PDF to text 的 5 类事故	4
4. Week7 和 Week8 的分界线	4
5. 一个合格 document asset 最少保留什么	5
6. OmniSupport 里的三个文档场景	6
7. 生产反模式	6
小白问答	6
课堂练习	7
本课最重要判断	7
自检清单	7
最小行动命令	7
延伸阅读	7
Footnotes	8

不是把 PDF 变成文本，而是把文档变成可追溯的数据资产

这一讲先立住 Week7 的核心判断：

非结构化数据工程的产出不是一堆 text chunks，而是能被检索、引用、质检和回放的 document asset。

这节课解决什么问题

Week03 已经能把文档拿进系统，但这还不等于 Week08 可以安全检索。

如果解析阶段只留下纯文本，下游会立刻遇到这些问题：

- 表格被打散，字段和含义断开
- 标题层级丢失，chunk 不知道自己属于哪个 section
- 页码和 bbox 丢失，citation 无法回指原文
- 解析策略变化后，坏案例无法复盘
- 质量不合格的 chunk 被直接送进索引

所以 Week7 的目标是把 raw document 升级成：

parsed document + knowledge sections + document chunks + evidence anchors + quality gate。

先用大白话讲

如果你是第一次接触非结构化数据工程，可以把 PDF to text 想成：把一本维修手册的每一页都撕下来，再揉成一团文字。文字还在，但目录、页码、表格、图片位置、版本和来源都不可靠了。

RAG 真正需要的不是“文字堆”，而是一张张证据卡片：这段话来自哪份手册、哪一章、哪一页、哪个表格、哪个版本，质量是否过关，是否允许进入索引。

在 OmniSupport 里，Northstar Edge Gateway 安装手册里的接线图、错误码表和故障排查步骤如果只保留正文，后续回答很容易“看起来对”，但引用不稳、表格错配、版本不可复盘。

技术内涵：非结构化数据工程到底工程化了什么

工程化对象	为什么重要	缺了会怎样	OmniSupport 例子
文档形状	layout、reading order、heading hierarchy 决定读者怎么理解文档	标题和正文混成一团，chunk 不知道自己属于哪个问题	Help Center 的 SSO 故障章节被切到错误主题下
文档位置	page_no、bbox、section_path、source_url 决定能否回指原文	citation 无法定位，用户质疑时只能全文搜索	Edge Gateway PDF 回答了错误码，却找不到页码
文档版本	source_fingerprint、doc_version、parse_strategy 支撑复盘	文档更新后无法证明当前回答引用的是哪版	Release Notes v1/v2 的变更说明被混用
文档质量	empty chunk、orphan chunk、anchor coverage、bbox coverage 决定能否索引	Week8 更快找到坏资料，而不是更稳回答	空 chunk 或无 anchor chunk 被建索引
消费边界	<code>allowed_for_indexing</code> 决定 Week8 能不能消费	warn/fail/quarantine 混在一起，索引准入失控	<code>week8_ready_gate.json</code> 只写 pass，不写原因

外延边界：这节课不讲什么

不讲什么	为什么以后会用到	本周只做什么
embedding	Week8 会把合格 chunk 写入索引	先保证 chunk 有结构、证据和质量状态
RAG API	Week8 response 会展示 citation	先生成 evidence anchor，禁止 LLM 临时拼 citation
OCR / VLM 生产化	扫描件和图片文档最终会需要更强能力	Student Core 只记录 capability 和 missing reason
完整治理	Week14 会处理 release / audit / governance	先保留 fingerprint、version、license_tag 和 quality flags

参考学习时间

按课程统一节奏完成即可。


学完这一讲，你应该能做到什么

1. 区分 raw document、parsed document、section、chunk、anchor。
2. 说明为什么“PDF to text”不能直接等价于 RAG 可用输入。
3. 解释 Week7 和 Week8 的边界。
4. 写出 Week7 document asset v1 的最小字段。
5. 判断一个解析结果是否具备进入 Week8 的基本资格。

本课产出

- docs/blueprints/week07/week07-execution-blueprint.md
- docs/blueprints/week07/document-asset-boundary.md

先看一张总图



1. “抽出文本”为什么不够

很多 RAG demo 会把文档处理简化成：

PDF -> text -> chunks -> embeddings

这条链路最大的问题不是“效果不够好”，而是工程对象不完整。它没有回答：

- 这段文字来自哪个文件版本？
- 来自第几页、哪个标题层级？
- 如果是表格，表头和行列关系还在不在？
- 这个 chunk 是否有证据锚点？
- 解析策略变更后，坏案例能不能复现？

! 核心判断

非结构化数据工程不是抽文本，而是把文档变成可追溯、可质检、可版本化、可供检索消费的数据资产。

2. Week7 的对象边界

对象	它是什么	不是	Week8 需要它做什么
raw document	原始文件或对象存储路径	已可检索内容	提供可校验的 raw bytes 和 <code>source_fingerprint</code>
parsed document	带布局和层级的解析结果	一串无结构文本	保留 page、bbox、table、heading 等 provenance
knowledge section	文档结构单元	最终检索 chunk	让 chunk 继承标题层级和上下文
document chunk	Week8 索引候选单元	生成阶段的 citation	成为可过滤、可质检、可索引的最小证据单元
evidence anchor	回指原文位置的证据对象	LLM 临时拼接的 URL	成为 citation 的唯一事实来源
quality gate	Week8 准入判断	人工随便看几个样本	决定哪些 chunk <code>allowed_for_indexing</code>

3. PDF to text 的 5 类事故

事故	表面看起来	生产里会坏在哪里
标题层级丢失	文本还在	检索命中后不知道属于哪个产品、版本或步骤
表格结构丢失	表头和数字都被抽出来了	Agent 可能把字段含义和数值错配
页码缺失	仍能生成答案	citation 无法回到原文页
bbox 缺失	页面级引用还能写	视觉定位、截图复核、法务审计都没法做
<code>doc_version</code> <code>source_fingerprint</code> 缺失	/ 当前样本能跑	版本变更后坏案例无法复现

4. Week7 和 Week8 的分界线

Week7 只做索引前的数据资产准备：

- parse
- normalize sections
- chunking
- evidence anchors
- quality report
- Week8 ready gate

Week8 才做：

- embedding
- pgvector / search index

- hybrid retrieval
- reranker
- RAG API
- citation rendering

如果 Week7 抢跑 Week8，会让课程主线变乱：学生还没有可验收 chunk，就开始讨论检索效果。

5. 一个合格 document asset 最少保留什么

字段	为什么必须保留
<code>source_fingerprint</code>	确认解析的是哪一份原始字节
<code>doc_version</code>	支撑版本回放和策略回归
<code>page_no</code>	PDF citation 的最小条件
<code>bbox / bbox_missing_reason</code>	支撑位置回指或解释为什么没有 bbox
<code>section_path</code>	保留标题层级和上下文
<code>parse_strategy_version</code>	解析策略可复现
<code>chunk_strategy_version</code>	chunk 策略可回归
<code>quality_flags</code>	告诉 Week8 哪些内容可消费、哪些要隔离

更工程化一点，可以把 Document Asset v1 看成四组字段：

字段组	代表字段	判断问题
Identity	<code>source_id</code> 、 <code>doc_id</code> 、 <code>source_fingerprint</code> 、 <code>doc_version</code>	这到底是哪份文档、哪一版、哪一次原始字节？
Structure	<code>section_id</code> 、 <code>section_path</code> 、 <code>section_type</code> 、 <code>chunk_id</code>	文档结构是否还在，chunk 是否能继承上下文？
Location	<code>page_no</code> 、 <code>bbox</code> 、 <code>bbox_missing_reason</code> 、 <code>source_url</code>	答案能否回到原文位置，不能回指时原因是否诚实？
Control	<code>parse_strategy_version</code> 、 <code>chunk_strategy_version</code> 、 <code>quality_flags</code> 、 <code>allowed_for_indexing</code>	策略能否回归，质量是否允许进入 Week8？

i 小白视角

如果把文档当成“证据”，Document Asset v1 就是在给证据贴标签：来源、位置、版本、结构、质量和是否允许被检索。

6. OmniSupport 里的三个文档场景

文档	为什么适合 Week7	重点风险
Northstar Edge Gateway 安装手册	有步骤、表格、错误码和页码，适合训练 structure-aware chunking	步骤被切断或错误码和修复建议分离
Workspace Help Center	有 HTML/Markdown 风格层级，适合训练 section_path 和 source_url	没有 bbox 时必须写清 not applicable
Release Notes	有版本、产品线、变更说明，适合训练 doc_version 与 source_fingerprint	版本混淆会导致 Week8 引用错 release

场景	本周最小动作	下游怎么用
安装手册 PDF	保留 page、bbox、表格和步骤边界	Week8 引用具体页码，Week11 检查答案是否引用正确证据
Help Center HTML / Markdown	保留 source URL、heading path、段落类型	Week8 能按主题检索，citation 回到具体帮助页或章节
Release Notes	保留版本、发布时间、产品线、source fingerprint	Week8 不把旧版本事实当成当前答案

7. 生产反模式

反模式	为什么危险	正确做法
只保留 <code>text</code>	下游无法回源、无法复盘	至少保留 source、version、section、page/bbox、策略版本
chunk 无来源	citation 只能靠猜	chunk 必须关联 evidence anchor
parser 输出无版本	解析策略升级后 ID 和质量不可比较	写入 <code>parse_strategy_version</code>
质量不达标却进入 Week8	坏 chunk 会变成检索噪声	只有 <code>allowed_for_indexing=true</code> 才能索引

小白问答

问题	回答
为什么不先把 PDF 都转成 Markdown?	Markdown 可以是中间表示，但不能替代 source fingerprint、page、bbox、section、quality gate。
没有 bbox 的文档是不是都不能用?	不是。HTML / Markdown 可以写 not applicable，但 PDF 缺 page 或 bbox reason 就不能装作没问题。

问题	回答
citation 能不能让 LLM 根据上下文写?	不能。LLM 只能消费已经存在的 evidence anchor，不能发明来源。
Week7 为什么不做 embedding?	因为 embedding 会放大输入质量问题。先让文档资产合格，再进入 Week8 索引。

课堂练习

给你一份 parsed output，只包含：

```
{"text": "Reset the device and retry provisioning."}
```

请判断它是否能进入 Week8，并写出至少 5 个缺失字段。参考答案应该包含：doc_id、source_fingerprint、doc_version、section_path、page_no 或 bbox_missing_reason、parse_strategy_version、chunk_strategy_version、evidence_anchor。

本课最重要判断

Week7 的输出不是“更多文本”，而是带结构、证据和质量状态的文档资产。

自检清单

- 我能解释 raw document 和 parsed document 的区别。
- 我能说清为什么 citation 不能由 LLM 临时生成。
- 我知道 Week7 不做 embedding、检索和 RAG API。
- 我能列出 document asset v1 的关键字段。

最小行动命令

```
# 可执行：已与主项目 Week7 runbook 对齐
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python -m pipelines.parse_normalize.run_parse \
    --manifest-path data/seed_manifests/manifest_workspace_helpcenter_v1.json \
    --parser auto \
    --chunk-strategy section_aware_v1 \
    --data-release-id week07-lesson01-smoke \
    --dry-run \
    --artifacts-dir artifacts/week07 \
    --report-json reports/week07/parse_run_report.json
```

延伸阅读

- Docling 官方文档：<https://docling-project.github.io/docling/>。先看整体能力边界，理解为什么本周采用 Docling-first，而不是只做 PDF to text。
- DoclingDocument 概念：https://docling-project.github.io/docling/concepts/docling_document/。重点看文档结构对象如何表达 page、text、table、picture 和 provenance。
- Unstructured document elements：<https://docs.unstructured.io/open-source/concepts/document-elements>。作为 fallback 对照，理解 elements 和 metadata 的表达方式。

- JSON Schema: <https://json-schema.org/understanding-json-schema/>。Week7 的 section、chunk、anchor 都应该先有 schema 边界。

Footnotes

1. “非结构化”不是“没有结构”，而是结构隐藏在版面、标题、表格、图片和文件版本里。
2. Week7 的核心产出是 document asset，不是检索服务。embedding、pgvector、hybrid retrieval 和 RAG API 属于 Week8。
3. `bbox_missing_reason` 不是降低要求，而是把能力缺口结构化，避免下游误判为成功解析。
4. `source_fingerprint` 应该基于原始字节计算，不应该基于 parser 输出后的文本计算。