

Week 7 | 课时 2 | 智能文档解析：布局、层级、表格、页码、坐 标与 provenance

本课导航

Parser 的价值不在“抽得多”，而在“保留得准”	1
这节课解决什么问题	1
先用大白话讲	2
技术原理：parser 负责生成哪些事实	2
参考学习时间	2
学完这一讲，你应该能做到什么	2
本课产出	2
Parser adapter 决策图	3
DoclingDocument 层级图	4
1. Student Core 为什么 Docling-first	4
2. Parser adapter 决策表	4
3. Parser 输出最少要归一成什么	5
4. MinIO raw object 是主路径	6
5. <code>bbox_missing_reason</code> 怎么写	6
6. 表格、图片占位和标题层级怎么处理	6
7. Parser capability report	6
8. 生产反模式	7
企业最佳实践	7
小白问答	7
本课最重要判断	8
自检清单	8
最小行动命令	8
延伸阅读	8
Footnotes	8

Parser 的价值不在“抽得多”，而在“保留得准”

这一讲进入 Week7 的解析层：

一个可用 parser 不只是输出文本，还要输出 layout、hierarchy、tables、page、bbox、provenance 和 parser capability。

这节课解决什么问题

到了解析层，最容易犯的错误是做工具横评：

Docling、Unstructured、Azure Document Intelligence 到底哪个抽文本效果更好？

这不是 Week7 的核心问题。Week7 真正要问的是：

哪个路线能在 Student Core 里稳定保留结构 metadata，并能被 contract、test 和 quality gate 验证？

先用大白话讲

Parser 不是“打字员”，不是把 PDF 里的字抄出来就结束。它更像“文档翻译官”：把人眼看到的标题、段落、表格、图片位置、页码和来源，翻译成系统能检查的对象。

在 OmniSupport 里，如果 Edge Gateway 的错误码表被解析成一段普通文字，后续 chunking 很可能把表头和修复动作拆散。看起来文本还在，但证据结构已经坏了。

技术原理：parser 负责生成哪些事实

层次	parser 要交付什么	为什么不是可选项
文档入口	raw object URI、source fingerprint、doc version	确认解析的是 Week3 接入的同一份原始文档
页面与布局	page_no、bbox、reading order	支撑 PDF citation 和视觉复核
语义结构	heading、paragraph、table、picture placeholder	支撑 section-aware chunking
provenance	parser backend、strategy version、span / location	支撑 bad case replay 和策略回归
capability	OCR 是否启用、fallback 是否发生、缺失字段原因	防止 fallback 输出伪装成完整解析

参考学习时间

按课程统一节奏完成即可。


学完这一讲，你应该能做到什么

1. 说明 Docling-first 为什么适合 Week7 Student Core。
2. 判断 parser 输出是否保留了 page、bbox、section path 和 provenance。
3. 区分 parser capability、parser output 和 quality gate。
4. 说明为什么 OCR、ASR、video、VLM caption 不作为本周必需路径。


本课产出

- docs/blueprints/week07/adr-parser-adapter-route.md
- contracts/data/knowledge_section.schema.json
- contracts/data/parse_run.schema.json

Parser adapter 决策图



DoclingDocument 层级图



这张图的重点不是让你背 Docling API，而是记住一件事：**parser 输出应该保留文档内部对象关系**。如果只剩一串 text，Page -> Section -> Table -> Provenance 这些关系就没了。

1. Student Core 为什么 Docling-first

Docling 路线适合本周，不是因为它“永远效果最好”，而是因为它天然贴近 Week7 的对象模型：

- 能表达 document hierarchy
- 能保留 page / bbox / provenance
- 能输出统一 document representation
- 能把 table、picture、text 分成不同结构对象
- 能本地执行，避免 Student Core 被云服务凭证和费用卡住

2. Parser adapter 决策表

路线	本周角色	适合做什么	不适合做什么
Docling	Student Core 默认	本地解析、结构保真、provenance、table / picture placeholder	不保证所有扫描件 OCR 都完美
Unstructured	optional fallback	elements 与 chunking 对照、某些格式 fallback	不作为第一必需路径

路线	本周角色	适合做什么	不适合做什么
OCR disabled	Student Core 默认	明确记录扫描件能力缺失	不能伪装成 OCR 已完成
ASR / VLM place-holder	Instructor Scale 预留	音频、视频、图片文档未扩展	不进入本周默认实验

3. Parser 输出最少要归一成什么

字段	作用	缺失时怎么处理
<code>section_id</code>	稳定引用 section	hard fail
<code>doc_id</code> / <code>source_id</code>	绑定文档与来源	hard fail
<code>section_path</code>	保留标题层级	HTML/MD/DOCX 必须有或说明缺失原因
<code>section_type</code>	区分 heading、paragraph、table、image placeholder	warning 起步
<code>content</code>	进入 chunk 的正文	空内容过滤并计入 quality report
<code>page_no</code>	PDF citation 最小定位	PDF hard fail
<code>bbox</code> / <code>bbox_missing_reason</code>	视觉位置或缺失解释	PDF 缺 bbox 必须有 reason
<code>source_fingerprint</code>	校验 raw bytes	hard fail
<code>parse_strategy_version</code>	解析策略回归	hard fail
<code>parser_capability</code>	说明 parser 能力与限制	fallback 必须写 warning

这些字段也可以按责任分成四类：

字段组	典型字段	消费方
Identity	<code>doc_id</code> 、 <code>source_id</code> 、 <code>source_fingerprint</code> 、 <code>doc_version</code>	quality gate、bad case replay
Structure	<code>section_id</code> 、 <code>section_type</code> 、 <code>section_path</code> 、 <code>content</code>	chunking、Week8 filter
Location	<code>page_no</code> 、 <code>bbox</code> 、 <code>bbox_missing_reason</code> 、 <code>source_url</code>	citation、人工复核
Runtime	<code>parser_backend</code> 、 <code>parse_strategy_version</code> 、 <code>parser_capability</code>	回归测试、fallback 分析

```
{
  "section_id": "stable_sha256_prefix",
  "doc_id": "workspace_help_center_v1",
```

```

"section_type": "paragraph",
"section_path": ["Setup", "SSO", "Troubleshooting"],
"page_no": 4,
"bbox": {"x0": 0.13, "y0": 0.22, "x1": 0.84, "y1": 0.31},
"bbox_missing_reason": null,
"content": "If SSO callback fails, verify the redirect URI...",
"source_fingerprint": "sha256...",
"doc_version": "v1",
"parse_strategy_version": "docling_v1_no_ocr"
}

```

这个 JSON 不是展示用字段，而是 Week8 citation、质量门禁和策略回归的事实基础。

4. MinIO raw object 是主路径

Week3 的 `doc_ingest.py` 会把文档写到类似这样的路径：

```
s3://omni-raw-documents/workspace-helpcenter/source.pdf
```

Week7 不能只从本地目录读文件。正确顺序是：

1. 解析 `s3://bucket/key`
2. 从 MinIO 下载 raw bytes
3. 对 raw bytes 重新计算 `source_fingerprint`
4. 与 `raw_doc_asset.source_fingerprint` 比对
5. 指纹不一致时 hard fail 或 quarantine
6. MinIO 失败时才允许 `source_dir` fallback，并写入 `fallback_reason`

5. bbox_missing_reason 怎么写

场景	推荐 reason	Gate
HTML / Markdown 没有页面坐 标	<code>not_applicable_non_paged_source</code>	not applicable
DOCX parser 只提供段落层级	<code>parser_did_not_emit_bbox</code>	warning
扫描 PDF 但 OCR 关闭	<code>ocr_disabled_in_student_core</code>	warning / quarantine
PDF parser 异常丢 bbox	<code>parser_bbox_missing</code>	warning 或 fail, 视 <code>page_no</code> 和 样本范围

6. 表格、图片占位和标题层级怎么处理

- 表格不要先拍平成普通段落，至少保留 `section_type=table`、表头、行列信息或 `table_data`。
- 图片不做 VLM 描述时也要保留 `image_placeholder`，说明图片存在、位置在哪里、当前没有语义描述。
- 标题层级进入 `section_path`，后续 chunk 继承它，而不是让 embedding 阶段再猜上下文。
- fallback parser 可以产生可用文本，但必须在 `parser_capability` 中写清结构能力不足。

7. Parser capability report

`parse_run_report.json` 至少要回答：

问题	为什么要写
使用了哪个 parser backend	方便复盘工具能力差异
是否启用 OCR	避免扫描件误判为完整解析
是否使用 fallback	防止 fallback 伪装成 Docling 等价能力
解析了多少 sections / tables / image place-holders	给 quality gate 提供输入
有哪些 warning	让 Week8 不盲目索引低质量内容

8. 生产反模式

反模式	风险
工具横评压过 schema-first	选了“抽文本强”的工具，却无法支撑 Week8 citation
只存 text，不存 provenance	一旦答案出错，找不到原文位置
fallback parser 无 warning	下游以为结构保真，实际 page/bbox/table 能力不足
OCR 结果伪装成可靠文本	扫描错误会直接进入检索资产

企业最佳实践

实践	为什么重要
先写 normalized section schema，再接 parser	防止工具输出牵着系统对象走
fallback 必须写 capability warning	让 Week8 知道哪些 chunk 结构保真度较低
对 PDF page_no 做 hard gate	没页码的 PDF citation 没法复核
对 HTML / Markdown 写 not applicable	不把非分页文档误判成 bbox 缺失
保留 parser 版本和策略版本	方便解释“为什么这次切出来和上次不一样”

小白问答

问题	回答
Docling-first 是不是说不能用别的 parser?	不是。它是 Student Core 默认路线，Unstructured、Azure、OCR 可以作为 optional / Instructor Scale，但要写清 capability。
OCR 关闭会不会影响效果?	会影响扫描件，但课程先把默认路径做稳；扫描件应进入 warning 或 quarantine，而不是伪装成功。
为什么要从 MinIO raw object 读?	因为 Week3 接入的是 raw asset，Week7 必须验证自己解析的是同一份原始字节。
parser output 能不能直接给 Week8?	不能。还要经过 chunking、anchor、quality gate，只有合格 chunk 才能索引。

本课最重要判断

Parser 不是工具选择题，而是 **结构元数据的生成器**。选型标准是：输出能否支撑 contract、quality gate 和 Week8 citation。

自检清单

- 我能解释 Docling-first 的 Student Core 理由。
- 我知道 Unstructured、OCR、ASR、VLM 在本周只是 optional / placeholder。
- 我能列出 parser 输出必须保留的字段。
- 我知道 `source_fingerprint` 必须基于真实 raw bytes 校验。

最小行动命令

可执行：已与主项目 Week7 runbook 对齐

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python -m pipelines.parse_normalize.run_parse \
  --manifest-path data/seed_manifests/manifest_workspace_helpcenter_v1.json \
  --parser auto \
  --chunk-strategy section_aware_v1 \
  --data-release-id week07-lesson02-parser \
  --dry-run \
  --artifacts-dir artifacts/week07 \
  --report-json reports/week07/parse_run_report.json
```

延伸阅读

- Docling DocumentConverter: https://docling-project.github.io/docling/reference/document_converter/。用来理解本地解析入口和可配置项。
- DoclingDocument 概念: https://docling-project.github.io/docling/concepts/docling_document/。重点看统一文档表示，不要只看文本抽取。
- Unstructured document elements: <https://docs.unstructured.io/open-source/concepts/document-elements>。作为 fallback route 的结构对照。
- Azure Document Intelligence layout model: <https://learn.microsoft.com/azure/ai-services/document-intelligence/prebuilt/layout>。作为 Instructor Scale 参考，理解 layout、table、page 坐标的能力上限。

Footnotes

1. Parser capability report 的价值在于记录“哪些能力没有发生”，不是只记录成功数量。
2. OCR disabled 是 Student Core 的默认限制，不是生产最佳实践；生产中扫描件应单独设计 OCR / VLM 质量门禁。
3. page、bbox、section_path 不是为了页面好看，而是为了后续 citation、bad case replay 和审计。
4. fallback parser 可以产生可用文本，但必须降低结构信任级别，并让 Week8 gate 看见这个事实。