

# Week 7 | 课时 4 | Evidence Anchor: 让每个 chunk 可以回指原文位置

## 本课导航

|                                                   |   |
|---------------------------------------------------|---|
| Citation 的事实来源必须在数据阶段生成 .....                     | 1 |
| 这节课解决什么问题 .....                                   | 1 |
| 先用大白话讲 .....                                      | 1 |
| 术语拆清楚 .....                                       | 2 |
| 参考学习时间 .....                                      | 2 |
| 学完这一讲，你应该能做到什么 .....                              | 2 |
| 本课产出 .....                                        | 2 |
| evidence anchor 映射图 .....                         | 2 |
| 1. Anchor 不是装饰字段 .....                            | 2 |
| 2. 为什么 anchor 要在数据阶段生成 .....                      | 3 |
| 3. Anchor contract 最小字段 .....                     | 3 |
| 4. 稳定 anchor ID .....                             | 4 |
| 5. page / bbox 缺失怎么处理 .....                       | 4 |
| 6. PDF / HTML / Markdown / DOCX 的 anchor 差异 ..... | 4 |
| 7. OmniSupport 下游会怎么消费 anchor .....               | 5 |
| 8. 生产事故：看起来有来源，但回不到原文 .....                       | 5 |
| 本课最重要判断 .....                                     | 5 |
| 自检清单 .....                                        | 5 |
| 最小行动命令 .....                                      | 5 |
| 延伸阅读 .....                                        | 6 |
| Footnotes .....                                   | 6 |

## Citation 的事实来源必须在数据阶段生成

这一讲把 Week7 的证据链收紧：

每个 chunk 至少要有个 evidence anchor，告诉 Week8 它来自哪个文件、哪个版本、哪一页、哪个 section、哪个 bbox。

## 这节课解决什么问题

很多系统把 citation 放到生成阶段，让 LLM 根据上下文“拼一个来源”。这会留下两个根本问题：

- 引用可能不是检索结果真实来源
- 出问题时无法回到原始文档定位

Week7 的做法是：

citation 只能消费 evidence anchor；LLM 不允许发明证据。

## 先用大白话讲

如果 chunk 是一张证据卡，那么 evidence anchor 就是卡片背面的“出处”：哪份文件、哪一版、哪一页、哪个章节、哪个坐标。如果背面没有出处，卡片上的话再像证据，也不能拿去回答用户。

OmniSupport 的目标不是“回答像不像”，而是当用户问“这句话从哪来”时，系统能把引用拉回真实文档。

术语拆清楚

| 对象              | 小白解释               | 工程职责                                |
|-----------------|--------------------|-------------------------------------|
| Section         | 文档里的章节或结构单元        | 保存标题层级、页码、bbox、content type         |
| Chunk           | 准备进入 Week8 索引的证据片段 | 继承 section/source meta-data，控制长度和质量 |
| Evidence Anchor | chunk 回源的稳定锚点      | 生成 citation、支持复盘和质量复核               |
| Citation        | 面向用户展示的引用          | 只能由 evidence anchor 投影出来，不能由 LLM 编造 |

参考学习时间

按课程统一节奏完成即可。


学完这一讲，你应该能做什么

- 1. 区分 chunk、section 和 evidence anchor。
- 2. 设计 evidence anchor 的最小字段。
- 3. 解释为什么 anchor 需要 source\_fingerprint 和 doc\_version。
- 4. 判断 page/bbox 缺失时应该 fail、warn 还是 not applicable。

本课产出

- docs/blueprints/week07/evidence-anchor-contract.md
- contracts/data/evidence\_anchor.schema.json

evidence anchor 映射图



1. Anchor 不是装饰字段

Evidence anchor 至少要支撑四类动作：

| 动作              | Anchor 提供什么               |
|-----------------|---------------------------|
| citation        | 文件、页码、section、bbox        |
| bad case replay | 原始对象、版本、指纹、策略版本           |
| quality review  | bbox 缺失原因、质量 flags        |
| policy filter   | license、visibility、PII 状态 |

没有 anchor, Week8 检索出来的 chunk 就只是“像证据的文本”。

## 2. 为什么 anchor 要在数据阶段生成

| 如果放到生成阶段              | 会发生什么          | 数据阶段生成的好处                                 |
|-----------------------|----------------|-------------------------------------------|
| LLM 根据上下文猜 source     | 引用可能不是检索结果真实来源 | citation 只来自已有 anchor                     |
| 生成时临时拼 page / section | 文档更新后难以复盘      | anchor 绑定 fingerprint / version           |
| 只在 UI 展示 URL          | 审计和评测无法消费      | anchor 可被 Week8 / Week11 / Week12 复用      |
| 缺失 bbox 时静默跳过         | 团队误以为可精确定位     | <code>bbox_missing_reason</code> 明确记录能力边界 |

## 3. Anchor contract 最小字段

```
{
  "anchor_id": "stable_sha256_prefix",
  "source_id": "doc:workspace:helpcenter:v1",
  "chunk_id": "document_chunk_id",
  "section_id": "knowledge_section_id",
  "doc_id": "workspace_help_center_v1",
  "source_fingerprint": "sha256...",
  "doc_version": "v1",
  "page_no": 4,
  "bbox": {"x0": 0.13, "y0": 0.22, "x1": 0.84, "y1": 0.31},
  "bbox_missing_reason": null,
  "section_path": ["Setup", "SS0"],
  "source_url": "s3://omni-raw-documents/workspace-help/source.pdf",
  "content_type": "pdf",
  "license_tag": "internal_training"
}
```

最小字段清单:

| 字段                                                         | 为什么必须有            |
|------------------------------------------------------------|-------------------|
| <code>anchor_id</code>                                     | citation 的稳定证据 ID |
| <code>source_id</code> / <code>doc_id</code>               | 绑定来源和文档           |
| <code>section_id</code> / <code>chunk_id</code>            | 绑定结构单元和索引候选单元     |
| <code>source_fingerprint</code> / <code>doc_version</code> | 支撑版本回放            |

| 字段                                   | 为什么必须有         |
|--------------------------------------|----------------|
| page_no / bbox / bbox_missing_reason | 支撑 PDF 回指和缺失解释 |
| section_path / source_url            | 支撑非分页文档定位      |
| content_type / license_tag           | 支撑过滤、权限和治理     |

## 4. 稳定 anchor ID

推荐公式：

```
anchor_id = sha256(
    chunk_id
    + anchor_type
    + source_fingerprint
    + doc_version
    + page_no
    + bbox
    + section_path
)[:32]
```

这样能保证：

- 同一 chunk 重跑后 `anchor_id` 不漂移
- bbox 或 section\_path 变化时，anchor ID 能反映事实变化
- Week8 citation 可以稳定引用同一证据对象

## 5. page / bbox 缺失怎么处理

| 文档类型            | page_no             | bbox                                                | Week7 gate                       |
|-----------------|---------------------|-----------------------------------------------------|----------------------------------|
| PDF             | 必须有                 | 缺失 warning, 并要求<br><code>bbox_missing_reason</code> | page 缺失 hard fail                |
| HTML / Markdown | 可为空                 | 可为空                                                 | 需要 section_path 和<br>source_uri  |
| DOCX            | 视 parser capability | 视 parser capability                                 | hierarchy 优先, bbox<br>作为 warning |
| scanned PDF     | 取决于 OCR             | 取决于 OCR                                             | Student Core 不强制<br>OCR, 报告中标明限制 |

## 6. PDF / HTML / Markdown / DOCX 的 anchor 差异

| 类型       | Anchor 重点                                       | 常见缺口              |
|----------|-------------------------------------------------|-------------------|
| PDF      | page_no、<br>bbox、source_fingerprint             | bbox 缺失但没有 reason |
| HTML     | source_url、section_path、DOM<br>语义               | 没有稳定 section path |
| Markdown | heading path、source repo<br>path、commit/version | heading 被当成普通段落   |

| 类型   | Anchor 重点                                       | 常见缺口                               |
|------|-------------------------------------------------|------------------------------------|
| DOCX | paragraph hierarchy、page capability、doc_version | parser 不输出页码却没有 capability warning |

## 7. OmniSupport 下游会怎么消费 anchor

| 下游                    | 需要 anchor 做什么                                  |
|-----------------------|------------------------------------------------|
| Week8 retrieval / RAG | 把 evidence_id、page、section、source 投影为 citation |
| Week11 eval           | 检查答案是否覆盖了正确证据                                  |
| Week12 tracing        | 回放一次坏答案时定位检索输入和引用来源                            |
| Week14 governance     | 对 release、source、license、PII 和 audit 做追责       |

## 8. 生产事故：看起来有来源，但回不到原文

最危险的 citation 不是完全没有来源，而是看起来像有来源：

Source: Workspace Help Center

Quote: Reset your device and retry provisioning.

这段引用缺少 `source_fingerprint`、`doc_version`、`page_no`、`section_path` 和 `anchor_id`。当文档更新或答案被质疑时，团队只能人工全文搜索，无法证明模型引用的是哪一份事实。

## 本课最重要判断

Evidence anchor 是 Week8 citation、Week11 eval、Week12 tracing 和 Week14 governance 的根。它必须在数据阶段生成。

## 自检清单

- 我能说明 citation 为什么不能由 LLM 临时发明。
- 我知道 evidence anchor 最少要保留哪些字段。
- 我知道 PDF、HTML、DOCX 的 page/bbox gate 不一样。
- 我能解释 `source_fingerprint` 对 bad case replay 的作用。

## 最小行动命令

# 可执行：已与主项目 Week7 runbook 对齐

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python -m pipelines.parse_normalize.run_parse \
  --manifest-path data/seed_manifests/manifest_workspace_helpcenter_v1.json \
  --parser auto \
  --chunk-strategy section_aware_v1 \
  --data-release-id week07-lesson04-anchor \
  --dry-run \
  --artifacts-dir artifacts/week07 \
  --report-json reports/week07/parse_run_report.json \
  --quality-report-md reports/week07/chunk_quality_report.md
```

## 延伸阅读

- DoclingDocument provenance: [https://docling-project.github.io/docling/concepts/docling\\_document/](https://docling-project.github.io/docling/concepts/docling_document/)。重点看元素如何保留 page、bbox 和 provenance。
- Unstructured metadata: <https://docs.unstructured.io/open-source/concepts/metadata>。作为 fallback 对照, 理解 source、page、coordinates 等 metadata。
- JSON Schema: <https://json-schema.org/understanding-json-schema/>。用于把 anchor contract 写成可测试边界。
- OpenAI Structured Outputs: <https://platform.openai.com/docs/guides/structured-outputs>。作为 Week8 预习, 理解为什么 citation 也要结构化输出, 但 citation 事实不能由模型生成。

## Footnotes

1. Anchor 是数据资产, 不是 UI 字段。UI citation 只是 anchor 的一种展示方式。
2. PDF page\_no 缺失通常应 hard fail; bbox 缺失是否 hard fail 要结合文档类型和 `bbox_missing_reason`。
3. `source_url` 不能替代 `source_fingerprint`。URL 可以指向新内容, fingerprint 才能锁定原始字节。
4. Week7 只生产 anchor, 不生产 embedding, 也不验证检索效果。