

Week 7: 非结构化数据工程

从“原始文档”到“带证据锚点的可检索文档资产”

Week7 不是 PDF 工具横评，也不是 RAG 索引课。

这一周只解决一个关键问题：

企业知识文档进入系统后，如何保留布局、层级、页码、坐标、版本、质量状态，并把每个 chunk 绑定到可回指原文的 evidence anchor。

本周默认 Student Core 路线是 Docling-first 文档解析、结构感知切片、evidence anchor 与质量门禁。Unstructured、OCR、ASR、video、VLM caption 都只作为 optional / Instructor Scale，不作为学员必需路径。

Week7 不生成 embedding、不写 pgvector、不做 hybrid retrieval、不做 reranker、不实现 RAG API。Week8 才开始索引和检索。

本周课程页对齐 `dataPro-lgtm/omnisupport-copilot` 当前 Week07 实现：`pipelines/parse_normalize/`、`contracts/data/knowledge_section.schema.json`、`document_chunk.schema.json`、`evidence_anchor.schema.json`、`reports/week07/`、`runbooks/week07-unstructured-data.md` 与 `docs/blueprints/week07/`。课程页只改讲义，不修改主项目代码。

本周一句话

把 Week3 已经 ingest 的 raw document asset 升级成 可切片、可质检、可引用、可被 Week8 安全索引的文档资产 v1。

换成项目语言就是：把 `raw_doc_asset` 推进成 `knowledge_section`、`document_chunk`、`evidence_anchor`、`chunk_quality_report.md` 和 `week8_ready_gate.json`。

先用大白话讲

非结构化数据工程不是“把 PDF 里的字抄出来”。更准确的说法是：把一本带目录、页码、表格、图片、版本和来源的手册，整理成机器能消费、团队能复盘、用户能追问来源的证据资产。

如果只把文档揉成一堆文本，Week8 的检索系统也许能“搜到一段话”，但它答不稳：不知道这段话来自哪个版本、哪一页、哪个表格，也不知道这段话是不是解析坏了、切片坏了或引用错了。

i 本周的主问题

Week7 不追求“抽出更多文本”，而是让每段文本都带着结构、位置、版本、质量状态和 evidence anchor 进入 Week8。

本周为什么重要

- 如果只做 PDF to text，标题层级、表格结构、页码和 bbox 很容易丢。
- 如果 chunk 没有 evidence anchor，Week8 的 citation 只能变成“看起来像引用”。
- 如果解析策略和切片策略没有版本，坏案例无法复盘，也无法做回归对比。

- 如果没有 quality gate, Week8 会把低质量 chunk 直接送进索引。

! Week7 的硬边界

Week7 只生产 Week8 可以安全消费的文档资产。它不评价检索好坏, 不生成向量, 不写 pgvector, 也不让 LLM 发明 citation。

本周在整门课里的位置

上承 Week03

Week03 负责把文档资产拿进系统: manifest、raw object、knowledge_doc、ingest report。

本周解决

Week7 把 raw document 变成 parsed sections、document chunks、evidence anchors、quality report 和 Week8 ready gate。

接住 Week06

如果 Week06 asset factory 已落地, Week7 可以挂到 Dagster asset graph; 如果还没有, 先走 devbox CLI fallback。

下接 Week08

Week8 只应该消费通过质量门禁、且能回指原文的 chunks。任何 citation 都必须来自 evidence anchor。

Week7 核心对象表

对象	小白解释	工程解释	项目路径 / 下游消费者 schema
raw document	原始文档文件	Week3 ingest 进来的 raw object 和 manifest 声明	data/seed_manifests/*、MinIO raw object parse / replay
parsed document	机器读懂后的文档结构	parser 输出的 layout、hierarchy、tables、page、bbox、provenance	pipelines/parse_normalize/ section normalize
knowledge_section	一段有层级的文档结构	标题路径、页码、bbox、section type 和 source metadata	contracts/data/knowledge_section.schema.json chunking
document_chunk	Week8 的候选索引单元	section-aware 切片结果, 继承 source / section metadata	contracts/data/document_chunk.schema.json Week8 index
evidence_anchor	chunk 背后的证据坐标	citation 的事实来源, 绑定 chunk、	contracts/data/evidence_anchor.schema.json citation / eval / tracing

对象	小白解释	工程解释	项目路径 / 下游消费者 schema
		section、source、page、bbox	
parse_run	一次解析运行记录	parser、策略版本、输入输出、warning 和 trace	contracts/data/parse_run/schema.json Funbook / report
chunk_quality_report	质量体检报告	metadata、anchor、page/bbox、empty/orphan/duplicate、PII heuristic	reports/week07/chunk_quality_report.md Week8 gate
week8_ready_gate	索引准入结论	明确哪些 chunk 可以进索引、哪些 fail / quarantine	reports/week07/week8_ready_gate.json Week8

五个课时

课时 1 | 为什么“抽出文本”不等于非结构化数据工程

问题：为什么 PDF to text 不能直接进入 RAG？

本课判断：非结构化数据工程的产物不是 text，而是可追溯、可质检、可回放的 document asset。

本课产物：[document-asset-boundary.md](#) 与对象边界表。

接下一课：明确对象边界后，开始决定 parser 必须保留哪些结构元数据。

进入课时 1

课时 2 | 智能文档解析：布局、层级、表格、页码、坐标与 provenance

问题：Parser 到底该追求“抽得多”，还是“保留得准”？

本课判断：Student Core 选择 Docling-first，是因为它更容易把 layout、hierarchy、page、bbox 和 provenance 归一到 contract。

本课产物：parser adapter 决策表与 [knowledge_section](#) 最小字段。

接下一课：parser 产出 sections 之后，才讨论怎么切成 chunks。

进入课时 2

课时 3 | 从 section 到 chunk：结构感知切片与 overlap 边界

问题：为什么 fixed-size chunk 很容易制造坏检索输入？

本课判断：先尊重文档结构，再处理长度；overlap 只能在同一 section 内谨慎使用。

本课产物：[section_aware_v1](#) 规则、稳定 [chunk_id](#) 和 chunk metadata 继承规则。

接下一课：chunk 只是候选索引单元，还必须绑定能回指原文的 evidence anchor。

进入课时 3

课时 4 | Evidence Anchor: 让每个 chunk 可以回指原文位置

问题: 为什么 citation 不能交给 LLM 在回答时临时拼?

本课判断: citation 的事实来源必须在数据阶段生成, Week8 只能消费 evidence anchor。

本课产物: `evidence_anchor.schema.json` 与 anchor 稳定 ID 规则。

接下一课: 有了 anchor, 还要判断这些 chunks 是否达到 Week8 准入质量。

[进入课时 4](#)

课时 5 | 解析质量与切片质检: 把 Week8 索引准入做成工程门禁

问题: 为什么“看起来差不多”的 chunks 不能直接建索引?

本课判断: 质量门禁是索引准入, 不是检索效果评估; pass / warn / fail / quarantine 要能解释。

本课产物: `chunk_quality_report.md` 与 `week8_ready_gate.json`。

接实验: 把 parse、section、chunk、anchor、quality 和 gate 跑成闭环。

[进入课时 5](#)

实验 | 把 Week3 文档资产升级成 Week8-ready 文档资产

实验目标是跑出 Week7 最小闭环:

- 读取 Week3 raw document asset
- 运行 Docling-first parse
- 生成 normalized sections
- 生成 section-aware chunks
- 为每个 chunk 生成 evidence anchor
- 输出 quality report 与 Week8 ready gate

[进入实验](#)


作业 | 提交文档资产 v1 与质检报告

作业要求你把 Week7 收口成可交接交付物:

- Week7 execution blueprint
- schema / contract 校验结果
- sections / chunks / anchors 样例
- `chunk_quality_report.md`
- `week8_ready_gate.json`
- 一份 bad case 复盘与修复建议

[进入作业](#)

Week3 → Week7 → Week8 主线图



Student Core / Instructor Scale 对比


能力	Student Core	Instructor Scale
Parser	Docling-first	Docling + Unstructured + OCR / VLM / ASR 扩展
Chunking	section-aware	semantic / layout-aware / multi-modal chunk
Evidence	page / bbox / section_path	visual grounding / richer provenance
Quality Gate	metadata / anchor / page / bbox / empty chunk	eval-assisted gate / production monitoring
Runtime	devbox CLI + thin Dagster wrapper	shared environment / full asset graph

Student Core 的目标是让每个学员都能在本地产出可交接资产包。Instructor Scale 用来演示生产扩展，但不能反过来污染主路径。

本周做 / 不做边界

分类	本周处理方式
必做	parse、normalize sections、structure-aware chunking、evidence anchor、quality report、Week8 ready gate
可选	Unstructured fallback、OCR flag、visual placeholder、ASR/video schema placeholder
明确不做	embedding、pgvector、hybrid retrieval、reranker、RAG API、tool calling、full eval harness
默认路径	Mac + Docker Compose + devbox CLI；Dagster 只是 thin wrapper
数据落点	PostgreSQL + MinIO parsed artifacts；Iceberg optional，不阻塞本周

实验闭环图



作业交付包地图

交付物	项目路径	验收重点
执行蓝图	docs/blueprints/week07/week07-execution-blueprint.md	说清 Week7 做 / 不做边界

交付物	项目路径	验收重点
Section contract	contracts/data/ knowledge_section.schema.json	page、bbox、section_path、 parser capability
Chunk contract	contracts/data/ document_chunk.schema.json	section_id、 chunk_strategy_version、an- chor 关联
Anchor contract	contracts/data/ evidence_anchor.schema.json	source_fingerprint、 doc_version、page/bbox/ source
Sections sample	artifacts/ week07/sections.json	normalized section 是否可复现
Chunks sample	artifacts/week07/chunks.json	section-aware、稳定 ID、非空
Anchors sample	artifacts/ week07/evidence_anchors.json	每个 chunk 至少一个 anchor
Quality report	reports/week07/ chunk_quality_report.md	指标、样本、warning、blocked reason
Week8 gate	reports/ week07/week8_ready_gate.json	allowed_for_indexing 与消费规 则
Bad case review	reports/ week07/bad_case_review.md	能解释失败原因和修复动作

本周交付物

- contracts/data/knowledge_section.schema.json
- contracts/data/document_chunk.schema.json
- contracts/data/evidence_anchor.schema.json
- contracts/data/parse_run.schema.json
- contracts/data/chunk_quality_sample.schema.json
- pipelines/parse_normalize/run_parse.py
- artifacts/week07/sections.json
- artifacts/week07/chunks.json
- artifacts/week07/evidence_anchors.json
- reports/week07/chunk_quality_report.md
- reports/week07/week8_ready_gate.json
- runbooks/week07-unstructured-data.md
- docs/blueprints/week07/week07-execution-blueprint.md

关键判断

- Week7 的核心不是“读出更多文本”，而是让文本、表格和图片占位带着结构、来源、策略版本和质量状态进入 Week8。
- Evidence anchor 是 citation 的事实来源，LLM 只能消费它，不能发明它。
- 质量门禁必须按文档类型判断：PDF、HTML、Markdown、DOCX 的 page / bbox 规则不同。
- 本周先保证 Student Core 可跑，再讨论 OCR、ASR、video、VLM caption 等 Instructor Scale 能力。

常见误区

误区	正确判断
抽出文本就等于 RAG-ready	RAG-ready 至少需要 section、chunk、anchor、质量状态和策略版本
chunk 越长越好	长 chunk 会吞掉无关上下文，降低 citation 精度
overlap 越大越好	跨 section overlap 会污染上下文，并制造重复命中
citation 可以由 LLM 生成	citation 只能来自 evidence anchor，LLM 只能引用已有证据
文档质量靠人工看几条样本就够	需要 metadata completeness、anchor coverage、empty/orphan/duplicate 等自动指标
OCR / VLM 是本周必需能力	Student Core 默认不强制 OCR / VLM；能力缺失要写进 parser capability
fallback parser 可以伪装成 Docling 等价能力	fallback 必须打 warning，不能假装拥有完整 layout / bbox 能力

延伸阅读

- Docling 文档入口：<https://docling-project.github.io/docling/>。读它是为了理解本周为什么选择 Docling-first，而不是为了做工具横评。
- Docling 的 DoclingDocument 结构说明：https://docling-project.github.io/docling/concepts/docling_document/。重点看统一文档表示、结构对象和 provenance。
- Unstructured document elements：<https://docs.unstructured.io/open-source/concepts/document-elements>。用于理解 fallback 路线里的 element / metadata 边界。
- LangChain recursive text splitter：https://docs.langchain.com/oss/python/integrations/splitters/recursive_text_splitter。用于理解 recursive splitter 为什么只是辅助，不应覆盖 parser 结构。
- JSON Schema 官方概念：<https://json-schema.org/>。用于把 section、chunk、anchor、quality sample 写成可测试契约。
- Week8 总览页：[从“搜得到”到“答得稳”](#)。读它是为了看 Week7 交出去的 chunks 会怎样被索引和引用。

Footnotes

1. “非结构化”不等于没有结构。企业文档通常有目录、页码、表格、图、版本和来源，只是这些结构没有天然落在数据库表里。
2. Docling-first 不等于只允许 Docling。它表示 Student Core 的默认路径用 Docling 保证本地可复现；fallback 可以存在，但必须记录能力损失。
3. Recursive splitter 是 fallback / 辅助工具，不是 Week7 默认主路径。默认主路径应该先尊重 parser 给出的 section、table 和 page 边界。
4. Evidence anchor 不是 citation 的装饰字段，而是 citation 的数据层事实来源。没有 anchor，Week8 的引用就无法证明来自哪份原文。
5. Week7 不做 embedding，是为了先保证 chunk 质量。把坏 chunk 更快送进向量索引，只会让 Week8 更难排查。