

Week 8 | 作业 | 提交 RAG Service Pack v1

本页结构

把“能回答”交付成可复现、可审计、可回归的服务证据包	1
作业目标	1
参考完成时间	1
必交工件	1
Week8 在项目里的位置	2
架构问题	2
评分 Rubric	2
不接受的作业	3
作业模板	3
最终提交判断	4

把“能回答”交付成可复现、可审计、可回归的服务证据包

Week8 作业不是让你写一篇 RAG 总结。

你要提交一组能证明系统可运营的报告、契约和架构判断。

作业目标

交付 Week8 RAG Service Pack v1:

- index build 可复现
- retrieval smoke 可解释
- RAG API response 契约完整
- no-answer 可控
- citation 来自 evidence
- audit 和 smoke eval 可用于后续回归

参考完成时间


2-3 小时

必交工件

工件	最低要求
<code>index_build_report_<index_release_id>.md</code>	说明 total / embedded / skipped / errors / provider / model / dim / warnings
<code>retrieval_smoke_report.md</code>	至少包含 vector-only、FTS-only、hybrid RRF、filter case
<code>rag_api_smoke_report.md</code>	至少包含 positive answer、no-answer、permission-like filter
<code>smoke_eval_report.md</code>	标明 pass / fail / placeholder

工件	最低要求
<code>rag_audit_log.sample.jsonl</code>	至少一条带 release ids、scores、evidence ids 的记录
<code>week08_delivery_summary.md</code>	回答 3 个架构问题

Week8 在项目里的位置



架构问题

在 `week08_delivery_summary.md` 中回答：

1. 为什么只做向量检索不够？
2. 为什么 citation 不能由 LLM 编造？
3. 为什么 `index_release_id` / `prompt_release_id` 要进入 response？

评分 Rubric

维度	权重	说明
契约完整性	20%	request / response / citation / index manifest 字段完整
索引可复现	20%	dry-run、build report、dimension guard、release id
检索可解释	20%	vector / FTS / RRF / filter / debug score 有证据
API 与引用可信	20%	answer / citation / no-answer / prompt release / trace id

维度	权重	说明
审计与回归	20%	audit sample、smoke eval report、失败说明清楚

不接受的作业

- 只有截图，没有报告和命令输出。
- answer 没有 citations / evidence_ids。
- citation 由 LLM 生成，没有 evidence metadata。
- 没有 index_release_id 或 prompt_release_id。
- reranker 不可用时直接让 API 失败。
- 把 Week10 tool action 或 Week11 full eval 当成 Week8 主交付。

作业模板

```
# Week8 Delivery Summary
```

```
## 1. Index Build
```

```
- index_release_id:
- data_release_id:
- chunk_strategy_version:
- embedding_model:
- embedding_dim:
- skipped/error:
```

```
## 2. Retrieval Smoke
```

```
- vector-only:
- FTS-only:
- hybrid RRF:
- filter case:
```

```
## 3. RAG API Smoke
```

```
- positive answer:
- no-answer:
- prompt_release_id:
- trace_id:
```

```
## 4. Audit / Eval
```

```
- audit sample:
- smoke eval result:
- known limitations:
```

```
## 5. Architecture Answers
```

```
### 为什么只做向量检索不够？
```

```
### 为什么 citation 不能由 LLM 编造？
```

为什么 release ids 要进入 response?

最终提交判断

你提交的不是“一个 RAG demo”，而是一份能让别人复现、排错、回滚和评估的 RAG 服务证据包。