

Week 8 | 实验 | 跑通最小 RAG 工程闭环

本页结构

从 contract 到 index, 再到 RAG API、audit 和 smoke eval	1
这次实验要完成什么	1
参考实验时间	1
本次实验产出	1
先看一张闭环图	2
0. 环境准备	2
1. 跑契约测试	2
2. Index dry-run	2
3. Index build	3
4. 调用 RAG API	3
5. 跑 smoke eval	3
6. 查看 audit sample	3
常见错误与排查	4
提交清单	4
实验最重要判断	4

从 contract 到 index, 再到 RAG API、audit 和 smoke eval

这次实验不是让你接一个外部向量数据库。

你要用项目内的 PostgreSQL + pgvector + FTS 路线, 跑出 Week8 最小闭环。

这次实验要完成什么

- 启动 Docker Compose
- 跑 RAG contract tests
- 跑 index build dry-run
- 跑 index build 或记录 fallback
- 调用 `/rag/answer`
- 检查 citations / evidence_ids / release ids / trace id
- 跑 smoke eval
- 查看 audit log / report

参考实验时间


90—120 分钟

本次实验产出

- `reports/week08/index_build_report_<index_release_id>.md`
- `reports/week08/retrieval_smoke_report.md`
- `reports/week08/rag_api_smoke_report.md`
- `reports/week08/smoke_eval_report.md`
- `reports/week08/rag_audit_log.sample.jsonl`

- reports/week08/week08_lab_execution_summary.md

先看一张闭环图



0. 环境准备

```
cp infra/env/.env.example infra/env/.env.local
```

```
docker compose --env-file infra/env/.env.local -f infra/docker-compose.yml up -d --build
```

验收：

```
curl http://localhost:8000/health
```

你应该看到 `release_id`、`data_release_id`、`index_release_id`、`prompt_release_id` 相关字段。

1. 跑契约测试

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  pytest tests/contract/ -v
```

验收：

- request / response / citation / index manifest fixtures 通过
- no-answer response 也必须有 release ids 和 trace id

2. Index dry-run

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run --rm devbox \
  python -m pipelines.indexing.embedder \
  --index-release-id index-week08-dev \
  --batch-size 32 \
  --dry-run
```

你要检查：

- 本次候选 chunks 数
- provider / model / dim
- 是否出现 dimension mismatch
- 是否标记 synthetic fixture / placeholder
- 是否生成 report

3. Index build

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python -m pipelines.indexing.embedder \
  --index-release-id index-week08-dev \
  --batch-size 32
```

如果没有 embedding key, 允许走 local fallback 或记录 structured skipped, 不允许伪造成功。

4. 调用 RAG API

```
curl -X POST http://localhost:8000/rag/answer \
-H "Content-Type: application/json" \
-d '{
  "question": "How do I recover an Edge Gateway after firmware upgrade failure?",
  "product_line": "edge-gateway",
  "top_k": 5,
  "index_release_id": "index-week08-dev",
  "prompt_release_id": "prompt-week08-v1",
  "include_debug": true
}'
```

验收:

- answer case 必须有 citations 和 evidence_ids
- no-answer case 必须有 abstain_reason
- response 必须有 release_id、data_release_id、index_release_id、prompt_release_id、trace_id
- debug 中能看到 vector / fts / rrf / rerank 相关分数

5. 跑 smoke eval

```
docker compose --profile tools --env-file infra/env/.env.local -f infra/docker-compose.yml run
--rm devbox \
  python evals/week08/run_smoke_eval.py
```

验收:

- reports/week08/smoke_eval_report.md 生成
- known-hit case 有 answer + citations, 或在空数据环境中明确 structured abstain
- no-answer case 有 abstain_reason
- filter case 不绕过 metadata filter

6. 查看 audit sample

```
tail -n 5 reports/week08/rag_audit_log.sample.jsonl
```

重点看:

- question
- filters
- retrieved_evidence_ids
- scores

- answer
- release ids
- latency_ms

常见错误与排查

问题	可能原因	处理
contract test 失败	schema 与 fixture 不一致	先修 contract, 不要先修 run-time
index build 无输出	Week7 chunks 不存在或 provider key 不可用	使用 dry-run / synthetic fixture fallback 并明确标记
dimension mismatch	embedding 模型维度与 pgvector 列不一致	hard fail, 修改配置或 migration
RAG API 无 citation	retrieval projection 缺 evidence metadata	修 retrieval, 不要让 LLM 编 citation
reranker 失败	Cross-Encoder 不可用	fallback 到 RRF, 记录 warning

提交清单

- reports/week08/index_build_report_<index_release_id>.md
- reports/week08/retrieval_smoke_report.md
- reports/week08/rag_api_smoke_report.md
- reports/week08/smoke_eval_report.md
- reports/week08/rag_audit_log.sample.jsonl
- reports/week08/week08_lab_execution_summary.md

实验最重要判断

这次实验不是追求“回答最好看”，而是证明 RAG 回答能被证据、版本、prompt 和审计记录复现。