

Week 8 | 课时 1 | 为什么“搜得到”不等于“答得稳”：RAG 工程闭环的系统边界

本课导航

稳定回答不是模型能力问题，而是证据、检索、生成和审计共同约束的结果	1
这节课解决什么问题	1
参考学习时间	1
学完这一讲，你应该能做到什么	1
本课产出	1
先看一张总图	2
1. 真正的问题不是“能搜到”，而是“能负责”	2
2. Week8 的对象边界	2
3. Week8 不抢跑后续周	2
4. 最小 RAG 响应长什么样	3
本课最重要判断	3
自检清单	3

稳定回答不是模型能力问题，而是证据、检索、生成和审计共同约束的结果

这一讲先立住 Week8 的边界：

RAG 工程不是让模型“多看一些资料”，而是让每次回答都能回到证据、版本、口径和审计记录。

这节课解决什么问题

很多 RAG demo 的问题不是“搜不到”，而是：

- 搜到了旧版本内容
- 搜到了无权限内容
- 搜到了不适合回答的低质量 chunk
- 生成阶段把 citation 编得像真的
- 出错后无法复现当时的索引、prompt 和证据

Week8 要把这件事收成工程闭环。

参考学习时间

45—55 分钟


学完这一讲，你应该能做到什么

1. 解释为什么“搜得到”不等于“答得稳”。
2. 说清 Week7、Week8、Week10、Week11 的边界。
3. 判断 citation、release id、trace id 在 RAG 响应里的作用。
4. 写出一个 RAG API 最小响应需要哪些字段。

本课产出

- [docs/blueprints/week08/week08-rag-blueprint.md](#)

先看一张总图



1. 真正的问题不是“能搜到”，而是“能负责”

RAG 系统的用户不会问：

你是否做了 embedding?

用户真正关心的是：

- 这个答案依据的是哪几段证据？
- 这些证据是否有权限、是否过期、是否可回指？
- 如果答案错了，能否复现当时的索引和 prompt？
- 如果证据不足，系统会不会拒答？

! 核心判断

RAG 的工程化标准不是“回答看起来像”，而是 answer、citation、release、trace、audit 可以同时解释。

2. Week8 的对象边界

对象	职责	不能混淆成
<code>data_release_id</code>	数据资产版本	当前数据库状态
<code>index_release_id</code>	索引版本	embedding 模型名
<code>prompt_release_id</code>	prompt 版本	代码部署版本
<code>evidence_id</code>	可引用证据	LLM 生成的一段文字
<code>trace_id</code>	一次请求追踪	用户会话 ID
<code>abstain_reason</code>	拒答原因	模型失败

3. Week8 不抢跑后续周

Week8 做：

- 索引资产化
- 混合检索

- metadata filter
- rerank fallback
- 结构化 RAG API
- Prompt as Code
- audit + smoke eval

Week8 不做:

- Week10 的 tool calling / ticket action
- Week11 的 full RAGAS / LLM-as-judge
- Week12 的 tracing 深度复盘平台
- Week13 GraphRAG
- Week14 release governance 全量流程

4. 最小 RAG 响应长什么样

```
{
  "answer": "Use the firmware recovery runbook and follow the rollback checklist.",
  "citations": [
    {
      "evidence_id": "ev-edge-gateway-001",
      "chunk_id": "ks-edge-001",
      "doc_id": "doc-edge-gateway-recovery",
      "source_id": "manual-edge-gateway-v3",
      "page_no": 12,
      "score": 0.91
    }
  ],
  "evidence_ids": ["ev-edge-gateway-001"],
  "confidence": 0.86,
  "abstain_reason": null,
  "release_id": "rag-api-dev",
  "data_release_id": "data-week08-dev",
  "index_release_id": "index-week08-dev",
  "prompt_release_id": "prompt-week08-v1",
  "trace_id": "trace-..."
}
```

本课最重要判断

如果一个 RAG API 不能返回 citation、release id、trace id 和 no-answer reason，它就还不是可运营的企业级 RAG 接口。

自检清单

- 我能解释为什么 citation 不能由 LLM 临时发明。
- 我能说清 `index_release_id` 与 `prompt_release_id` 的价值。
- 我知道 Week8 不做 tool action 和 full eval。
- 我能读懂一个结构化 RAG 响应是否具备审计条件。