

Week 8 | 课时 4 | 重排与生成门禁: Cross-Encoder rerank、证据筛选与 no-answer 策略

本课导航

Rerank 是候选证据门禁，不是让模型自由发挥的许可证	1
这节课解决什么问题	1
参考学习时间	1
先看一张总图	2
1. Rerank 的正确位置	4
2. Reranker 不可用不能让链路失败	4
3. No-answer 是受控行为	4
4. Citation 只能来自 retrieval metadata	4
5. 生成门禁的最小判断	5
本课最重要判断	5
自检清单	5

Rerank 是候选证据门禁，不是让模型自由发挥的许可证

这一讲讲清楚：rerank 放在哪里、不可用怎么办、什么时候必须 no-answer，以及 citation 为什么只能从检索结果来。

这节课解决什么问题


Hybrid retrieval 只完成候选召回。真正进入生成前，还要回答：

- top candidates 是否足够可信？
- reranker 不可用时系统是否还能服务？
- evidence score 太低时是否拒答？
- citation 从哪里来？
- no-answer 是否是结构化产品能力？

参考学习时间

45–55 分钟

先看一张总图



1. Rerank 的正确位置

Cross-Encoder rerank 应该只作用在 Top-N candidates 上。

它不负责：

- 重新检索全库
- 绕过权限过滤
- 生成 citation
- 决定是否可以调用工具

2. Reranker 不可用不能让链路失败

课堂默认降级策略：

情况	行为
reranker model 未安装	fallback 到 RRF
reranker 超时	fallback 到 RRF, 记录 warning
reranker 返回异常	fallback 到 RRF, 写入 debug/audit
reranker 可用	写入 <code>rerank_score</code> 和 <code>final_score</code>

3. No-answer 是受控行为

这些情况应该返回结构化 no-answer：

- 无检索结果
- 权限过滤后无结果
- evidence score 低于阈值
- 证据互相冲突，无法稳定回答
- prompt 或模型不可用且不能安全 fallback

```
{
  "answer": "当前知识库未覆盖这个问题，不能给出可靠回答。",
  "citations": [],
  "evidence_ids": [],
  "confidence": 0.0,
  "abstain_reason": "no_retrieval_results"
}
```

4. Citation 只能来自 retrieval metadata

生成器可以组织语言，但不能发明：

- `source_url`
- `page_no`
- `section_path`
- `bbox`
- `doc_version`
- `evidence_id`

⚠ 常见错误

让 LLM “顺便生成引用”会把 citation 变成新的幻觉面。正确做法是：retrieval result 投影 citation, generator 只消费 evidence。

5. 生成门禁的最小判断

判断	说明
<code>candidate_count > 0</code>	没候选不能回答
<code>final_score >= threshold</code>	候选证据要过最低分
<code>citation_count > 0</code>	有答案必须有引用
<code>filter_applied=true</code>	权限和版本过滤必须已执行
<code>prompt_release_id present</code>	prompt 版本可复现

本课最重要判断

Rerank 是证据排序工具，不是安全兜底。真正的安全兜底是 evidence gate + structured no-answer。

自检清单

- 我能解释 rerank 不可用时为什么要 fallback 到 RRF。
- 我知道 no-answer 要结构化返回。
- 我能说清 citation 为什么不能由模型临时生成。
- 我能画出 retrieval → rerank → gate → generation 的顺序。