

Week 8: 从“搜得到”到“答得稳”——检索 × 生成的一体化工程闭环

把 Week7 的证据资产升级成可版本化、可审计、可回归的 RAG 服务

Week8 不是“讲一个 RAG 框架”，也不是把文档塞进向量库。

这一周只解决一个关键问题：

当系统回答一个问题时，我们能不能说清它用了哪一版数据、哪一版索引、哪一版 prompt、哪些证据，以及为什么可以回答或应该拒答。

Student Core 路线：PostgreSQL + pgvector + PostgreSQL FTS + RRF + optional Cross-Encoder rerank + 结构化 RAG API contract。

本周不做 Week10 tool action、Week11 full eval、Week12 tracing、Week13 GraphRAG，也不把 Pinecone / Weaviate / Qdrant 作为必需路径。


本周一句话

把 Week7 的 sections / chunks / evidence anchors 升级成 可版本化索引、混合检索、证据引用、结构化回答、Prompt as Code 与审计回归闭环。

本周为什么重要

- 只做向量检索，遇到产品型号、错误码、版本号和权限边界时会很脆弱。
- 如果 citation 由 LLM 临时生成，引用就不是证据，而是新的幻觉来源。
- 如果没有 `index_release_id` 和 `prompt_release_id`，一次错误回答很难复现。
- 如果 no-answer 没有契约，系统会被迫“编一个看起来合理的答案”。

Week7 → Week8 → Week10/11 主线图



五个课时

课时 1 | 为什么“搜得到”不等于“答得稳”

- RAG 工程闭环边界

- answer、citation、release id 的责任拆分
- 为什么 no-answer 是产品能力

[进入课时 1](#)

课时 2 | 索引资产化

- embedding 与 index release
- 增量更新、回滚与 index manifest
- dry-run / build report / dimension guard

[进入课时 2](#)

课时 3 | 混合检索

- pgvector + PostgreSQL FTS
- RRF fusion
- metadata filter 与 debug score

[进入课时 3](#)

课时 4 | 重排与生成门禁

- Cross-Encoder rerank 的位置
- evidence gate 与 no-answer 策略
- citation 只能来自检索结果

[进入课时 4](#)

课时 5 | RAG API 契约化

- request / response / citation schema
- Prompt as Code
- audit log 与 smoke eval

[进入课时 5](#)

实验 | 跑通最小 RAG 工程闭环

实验会按 Docker Compose + devbox 路径完成：

- contract tests
- index dry-run
- index build
- hybrid retrieval smoke
- /rag/answer 调用
- smoke eval 与 audit sample

[进入实验](#)

作业 | 提交 Week8 RAG Service Pack v1

作业要求你提交可复现的证据包：

- index_build_report
- retrieval_smoke_report
- rag_api_smoke_report
- smoke_eval_report

- 3 个架构判断题

[进入作业](#)

本周做 / 不做边界

分类	本周处理方式
必做	index release、hybrid retrieval、metadata filter、rerank fallback、RAG API contract、Prompt as Code、audit、smoke eval
可选	Cross-Encoder rerank、OpenAI Structured Outputs、Instructor Scale 的外部向量数据库对比
明确不做	tool action、HITL、full RAGAS、LLM-as-judge 主流程、Phoenix 深度 tracing、GraphRAG、lakeFS/OpenLineage release workflow
默认路径	Docker Compose + devbox；本机 venv 不是默认要求
降级路线	Week7 未完成时使用 synthetic ready chunks；embedding key 不可用时 dry-run / local fallback；reranker 不可用时 RRF fallback

本周交付物

- `contracts/release/index_manifest.schema.json`
- `contracts/service/rag_request.schema.json`
- `contracts/service/rag_response.schema.json`
- `contracts/service/citation.schema.json`
- `contracts/service/retrieval_debug.schema.json`
- `reports/week08/index_build_report_<index_release_id>.md`
- `reports/week08/retrieval_smoke_report.md`
- `reports/week08/rag_api_smoke_report.md`
- `reports/week08/smoke_eval_report.md`
- `runbooks/week08-rag-engineering.md`

关键判断

- 检索质量不是只看 top1 是否像，而是看 evidence、filter、release、prompt 和 audit 能否一起闭环。
- citation 不能由 LLM 发明，只能从 retrieval result 的 metadata 投影出来。
- `index_release_id`、`data_release_id`、`prompt_release_id` 是 RAG 回答可复现的最低条件。